

マーケティング・データ分析の学習メモ

Table of contents

第1章　はじめに	5
1.1　準備	5
第I部　第1部	7
第1章 R と Rstudio に慣れる	9
第2章 リサーチ・デザインと問い合わせの設計	9
第3章 尺度と質問紙調査設計	9
第2章　データ整理と要約	11
2.0.1　dplyr でデータの要約	12
2.0.2　企業データの処理	13
2.1　4 データの要約	15
2.2　カテゴリ変数の要約	16
第II部　第2部 仮説検証型データ分析	21
第3章　第5章	25
第4章　第6章	31
第5章　第7章	37
第6章　第8章	53
第III部　第3部 探索型データ分析	65
第7章　第10章セグメントとクラスター分析	69
7.1　階層的クラスター分析	69
第8章　第11章	81
第9章　第12章	89

第1章

はじめに

このノートは、神戸大学の田頭拓己先生が書かれた「マーケティング・データ分析」に関する学習内容をまとめたものです。統計学の基礎を学習し、その知識を使ってマーケティングについて各自が持っている問題意識や、抱えている課題について深く理解し、解決するための糸口を見つける力を養う、という点で非常に優れたテキストです。

1.1 準備

各自の PC(Windows か Mac を想定) の好きな場所に Marketing_data_analysis というフォルダを作成し、そこを作業ディレクトリにしていることを想定しています。この文章の意味が分からぬ人は、R の入門書を確認してください。作業ディレクトリの中に data というフォルダを作成し、そこにテキストで使うデータファイルを保存してある、という前提で進めます。

第Ⅰ部

第1部

第1章 R と Rstudio に慣れる

R と R を便利に使うための統合環境である Rstudio の基本的な使い方を学びます。R 初学者はしっかり読んで準備しておいてください。ただ、この章の内容は、数多く出版されている R の解説書で代替できるため、割愛します。

また、この本ではコードを書く環境として Rstudio を想定していますが、個人的には Microsoft 社が開発している Visual Studio Code (VSCode) や Posit 社が開発している Positron を推奨しているので、この章の内容には触れません。

第2章リサーチ・デザインと問い合わせの設計

経営学部生がビジネスに関する問い合わせる際に重要なポイントを解説しています。

必読です。

ただ R のコードは出てこないので、ここでは解説しません。各自で熟読しておきましょう。

第3章尺度と質問紙調査設計

マーケティング研究でよく利用されている質問紙を使ったアンケート調査の設計方法について解説しています。いろんなところで利用されているアンケートですが、設計段階でいろんな人の思いが錯綜し、本来知りたかった事を調査できていないことがあります。

第4章は「データ整理と要約」というテーマで、R を使ってデータの整理や要約を行う方法について解説しています。データ分析の前にデータを適切に整理し、要約することは非常に重要です。この章では、R の基本的なデータ操作や要約統計量の計算方法について学びます。

第 2 章

データ整理と要約

第 4 章は、データを読み込んで、形を整えて、特徴をつかむためのデータを要約する方法を学びます。R は最初から用意されている基本関数だけでも十分強力ですが、外部で開発された様々なパッケージを使うと、さらに便利にデータ操作ができます。

はじめに外部のパッケージをインストールして R の機能を拡張します。R でデータを操作する際に超強力なパッケージ群である `tidyverse` を読み込みます。あとで使う Excel ファイルを読み込むための `readxl` パッケージも一緒に読み込みます。

テキストでは、`install.packages()` 関数でパッケージをインストールして、`library()` 関数で読み込んでいますが、ここでは `pacman` パッケージを使って、必要なパッケージを一括でインストールおよび読み込みをします。

まず始めに、`pacman` パッケージをインストールします。この作業はここで 1 回だけです。以降はこのコードは実行しなくて大丈夫です。

```
# first time only
install.packages("pacman")
```

次に、`pacman` パッケージの `p_load()` 関数を使って、`tidyverse` と `readxl` パッケージをインストールおよび読み込みします。`::` という記法はパッケージ名を明示的に指定して関数を使う方法ですが、ここでは `pacman` パッケージの `p_load()` 関数を指定して使っています。

```
pacman::p_load(tidyverse, readxl, gt, gtExtras)
```

作業ディレクトリ内の `data` フォルダに入っている `2022idpos.csv` というデータを読み込みます。何を読み込んだのか確認するために、基本関数 `head()` でデータの先頭 6 行を表示させます。

```
idpos <- readr::read_csv("data/2022idpos.csv", na = ".")
idpos |> head()
```

```
# A tibble: 6 x 4
  id     date    spent   coupon
  <dbl>   <date> <dbl>   <dbl>
1 1      2022-01-01 100.0  0.00
2 2      2022-01-01 150.0  0.00
3 3      2022-01-01 200.0  0.00
4 4      2022-01-01 250.0  0.00
5 5      2022-01-01 300.0  0.00
6 6      2022-01-01 350.0  0.00
```

一度 `pacman` パッケージをインストールすれば、あとは `pacman::p_load()` 関数を使うだけで、指定したパッケージがインストールされていなければ自動的にインストールし、読み込みまで行ってくれます。非常に便利です。

```

<dbl> <chr>      <dbl> <dbl>
1    12 2019/9/25 14326     1
2    32 2019/9/10 10232     1
3    30 2019/9/9  6881      1
4    29 2019/9/4  6365      0
5    46 2019/9/10 7595      1
6    44 2019/9/14 7858      0

```

`readr` パッケージの `read_csv()` 関数は、CSV 形式のデータを読み込むための関数です。`na = ". "`という引数は、データ内の。を欠損値として扱うことを指定しています。

読み込んだデータに含まれている変数の名前を確認するため、基本関数 `names()` を使います。

```
idpos |> names()
```

```
[1] "id"      "date"    "spent"   "coupon"
```

データの詳細を確認するため、`tidyverse` の `dplyr` パッケージの `glimpse()` 関数を使います。

```
idpos |> glimpse()
```

Rows: 3,000

Columns: 4

```
$ id      <dbl> 12, 32, 30, 29, 46, 44, 44, 32, 3, 34, 36, 3, 42, 18, 38, 4, 19-
$ date    <chr> "2019/9/25", "2019/9/10", "2019/9/9", "2019/9/4", "2019/9/10", ~
$ spent   <dbl> 14326, 10232, 6881, 6365, 7595, 7858, 9405, 1821, 8375, 1828, 6-
$ coupon  <dbl> 1, 1, 1, 0, 1, 0, 0, 0, 1, 1, 0, 0, 0, 1, 1, 1, 1, 1, 0, 1, ~
```

Excel のようにデータを表示させたいなら、基本関数 `View()` を使います。

```
View(idpos)
```

これで、自分が読み込んだデータがどんなものかを確認できました。

2.0.1 dplyr でデータの要約

`tidyverse` の `dplyr` パッケージを使うと、データの要約が簡単にできます。ここでは、

- `summarise()` 関数：データの要約統計量を計算する
- `mutate()` 関数：新しい変数を作成する
- `filter()` 関数：条件に合う行を抽出する
- `select()` 関数：特定の変数を抽出する
- `arrange()` 関数：データを並び替える
- `rename()` 関数：変数の名前を変更する

の使い方を学びます。

先ほど読み込んだデータには、

- `id` : 顧客 ID

- date : 購入日
- spent : 購入金額
- coupon : クーポン利用の有無 (1=利用, 0=未利用)

という 4 変数に 3,000 の観測値が含まれています。このデータを `dplyr` の各関数を使って、以下のような操作をしてみます。

まず、

1. `select()` 関数で `spent` と `coupon` を抽出し、
 2. `arrange()` 関数で `spent` の降順に並び替え、
 3. `mutate()` 関数で `spent` の金額を 10 倍した `spent10` という新しい変数を作成し、
 4. `filter()` 関数で `spent10` が 10000 以上の行を抽出し、
 5. `summarise()` 関数で `spent10` の平均を計算し、
 6. `rename()` 関数で `spent10` を `spent_times10` に名前変更する、
- という一連の操作を行います（この処理に意味はないです。）

```
# コード 4-11 (見本コード)
```

```
idpos |>
  select(spent, coupon) |>
  arrange(desc(spent)) |>
  mutate(spent10 = spent * 10) |>
  filter(spent10 >= 10000) |>
  summarise(mean_spent10 = mean(spent10)) |>
  rename(spent_times10 = mean_spent10)
```

```
# A tibble: 1 x 1
```

```
  spent_times10
  <dbl>
1     82391.
```

すると、`spent` を 10 倍して、1 万円以上の買い物の平均値を計算した結果が `spent_times10` として表示されます。

このように加工したデータを `csv` ファイルとして保存するには、`readr` パッケージの `write_csv()` 関数を使います。`write_csv()` 関数は、第 1 引数に保存したいデータフレームを指定し、第 2 引数に保存先のファイルパスを指定します。

```
readr::write_csv(idpos, path = "data/new_data.csv")
```

2.0.2 企業データの処理

MS Excel のファイルを読み込むこともできます。ここでは、`readxl` パッケージの `read_xlsx()` 関数を使って、企業データを読み込みます。

```

firmdata <- readxl::read_xlsx("data/MktRes_firmdata.xlsx")
firmdata |> glimpse()

Rows: 1,431
Columns: 31
#> #> $ fyear <dbl> 2011, 2012, 2013, 2014, 2015, 2016, 2017, 2018, ~
#> #> $ legalname <chr> "ハウステンボス株式会社", "ハウステンボス株
#> #> 式会社", "ハウステンボス株式会社", "\~"
#> #> $ ind_en <chr> "Miscellaneous Services", "Miscellaneous Servic~
#> #> $ parent <chr> "エイチ・アイ・エス", "エイチ・アイ・エス", "
#> #> エイチ・アイ・エス", "エイチ・アイ・~"
#> #> $ fiscal_month <chr> "2011/10", "2012/10", "2013/10", "2014/10", "20~
#> #> $ current_liability <dbl> 65509, 76206, 85459, 98384, 122993, 102805, 131~
#> #> $ ltloans <dbl> 0, 4781, 23411, 22780, 14319, 77042, 101603, 11~
#> #> $ total_liability <dbl> 73428, 96734, 125233, 179036, 194254, 237245, 3~
#> #> $ current_assets <dbl> 102810, 111697, 137515, 196789, 212979, 233531, ~
#> #> $ ppent <dbl> 12383, 40554, 45511, 48704, 60761, 62291, 83001~
#> #> $ total_assets <dbl> 139018, 173497, 215913, 281332, 308245, 332385, ~
#> #> $ net_assets_per_capital <dbl> 65589, 76763, 90680, 102295, 113990, 95139, 111~
#> #> $ sales <dbl> 380805, 431483, 479478, 523246, 537456, 523705, ~
#> #> $ sga <dbl> 61158, 65654, 69953, 80033, 88284, 90769, 98822~
#> #> $ operating_profit <dbl> 9407, 11316, 11843, 15906, 19970, 14274, 15915, ~
#> #> $ net_profit <dbl> 8958, 10881, 11190, 11271, 14025, 1305, 15835, ~
#> #> $ pnet_profit <dbl> 8300, 9331, 8903, 9050, 10890, 267, 13259, 1106~
#> #> $ re <dbl> 47658, 55966, 63664, 71612, 82150, 80988, 92731~
#> #> $ adv <dbl> 8565, 9691, 10694, 11665, 12969, 12647, 12371, ~
#> #> $ labor_cost <dbl> 30624, 31743, 31648, 37240, 40402, 41505, 46583~
#> #> $ rd <dbl> 0, 0, 0, 0, 0, 0, 176, 0, 0, 0, 0, 0, 0, ~
#> #> $ other_sg <dbl> 14962, 17078, 19720, 21648, 24043, 24710, 26067~
#> #> $ emp <dbl> 6265, 8310, 9026, 9652, 10143, 10845, 13510, 13~
#> #> $ temp <dbl> 1751, 2470, 2750, 3071, 3469, 3535, 3422, 3179, ~
#> #> $ tempratio <dbl> 0.2184381, 0.2291280, 0.2335258, 0.2413739, 0.2~
#> #> $ indgrowth <dbl> -0.0038649153, 0.0780674898, -0.0737512474, 0.0~
#> #> $ adint <dbl> 0.02249183, 0.02245975, 0.02230342, 0.02229353, ~
#> #> $ rdint <dbl> 0.0000000000, 0.0000000000, 0.0000000000, 0.000~
#> #> $ mkexp <dbl> 0.16060188, 0.15215895, 0.14589408, 0.15295482, ~
#> #> $ op <dbl> 0.02470293, 0.02622583, 0.02469978, 0.03039870, ~
#> #> $ roa <dbl> 0.0597044987, 0.0537819098, 0.0412342008, 0.032~

```

31変数1,431観測値からなるデータが読み込まれました。必要な変数が変わること

もあるかと思うので、先に必要な変数名をベクトル `vars_list` として保存しておきます。

必要な観測値と変数だけを抽出して、新しい変数を作成し、並び替えて、新しいオブジェクト `firm2018_check` に格納します。

```

1 # 必要な変数のリスト
2 vars_list <- c("legalname", "fyear", "sales", "labor_cost", "emp",
   ↪ "temp")
3
4 # コード 4-28
5 firm2018_check <- firmdata |>
6   filter(fyear == 2018) |> # 2018 年のデータを抽出
7   select(all_of(vars_list)) |> # 必要な変数を選択
8   mutate(wage = labor_cost / (temp + emp), na.rm = TRUE) |> # 新しい変
   ↪ 数 wage を作成
9   # temp + emp が 0 でないチェックが必要かも
10  arrange(desc(wage)) # wage の降順に並び替え
11 head(firm2018_check, n = 10) # 先頭 10 行を表示

```

	legalname	fyear	sales	labor_cost	emp	temp	wage	na.rm
	<chr>	<dbl>	<dbl>	<dbl>	<dbl>	<dbl>	<dbl>	<lgl>
1	株式会社リクルート	2018	2310756	388583	45856	2449	8.04	TRUE
2	株式会社 大丸松坂屋百貨店	2018	459840	62692	6695	3581	6.10	TRUE
3	株式会社 帝国ホテル	2018	58426	17307	1940	998	5.89	TRUE
4	株式会社 高島屋	2018	912848	83779	7761	8849	5.04	TRUE
5	株式会社コメリ	2018	346862	43991	4646	4777	4.67	TRUE
6	株式会社オートバックスセブン	2018	213840	22139	4171	747	4.50	TRUE
7	株式会社ロイヤルホテル	2018	40884	13115	2049	894	4.46	TRUE
8	オルビス株式会社	2018	248574	28555	4181	2330	4.39	TRUE
9	株式会社ファンケル	2018	122496	15103	1381	2213	4.20	TRUE
10	近畿日本ツーリスト株式会社	2018	411821	38186	6956	2189	4.18	TRUE

2.1 4 データの要約

大規模データをあつかうとき、データそのものを眺めていても特徴をつかむことは難しいので、そのデータを特徴付ける代表値を計算して、そこからデータの特徴をつかみます。主要な代表値として、平均値 (`mean()`) や中央値 (`median()`)、散らばり具合を示す分散 (`variance()`) や標準偏差 (`standard deviation`) があります。それぞれ、

- 平均値：`mean()` 関数
- 中央値：`median()` 関数

`all_of()` 関数は、`select()` 関数内で使用され、変数名のベクトルを指定して、その変数を選択するために使います。これにより、変数名が動的に指定でき、コードの柔軟性が向上します。

- 分散 : `var()` 関数
- 標準偏差 : `sd()` 関数

を使って計算します。

先ほどのデータ `firm2018_check` の `sales` 変数について、代表値を計算してみます。ここでは、`dplyr` パッケージの `summarize()` 関数を使って、平均、中央値、分散、標準偏差を一度に計算します。

```
firm2018_check |>
  summarize(
    mean_sales = mean(sales),
    median_sales = median(sales),
    var_sales = var(sales),
    sd_sales = sd(sales)
  )

# A tibble: 1 x 4
  mean_sales median_sales var_sales sd_sales
  <dbl>       <dbl>      <dbl>     <dbl>
1 1242425.     526675     3.69e12 1921062.
```

2.2 カテゴリ変数の要約

つぎに、データ上は数値や文字列として記録されていても、その数値や文字列がカテゴリーを表す名義尺度 (nominal scale) である場合を考えましょう。

例えば、`firmdata` の中の産業分類を表す `ind_en` 変数は、文字列で表現されていますが、その文字列はある観測値が所属するカテゴリーを表しています。`fyear` 変数は数値ですが、これは年度を表すカテゴリー変数です。

カテゴリー内の観測値の頻度を確認するには基本関数 `table()` を使いますが、ここでは、`dplyr::count()` 関数を使って、`ind_en` 変数の各カテゴリーの頻度を計算し、`gt` パッケージで表形式で表示します。

```
firm2018 <- firmdata |>
  filter(fyear == 2018) # 2018年のデータを抽出
firm2018 |>
  dplyr::count(ind_en, name = "企業数") |>
  gt::gt() |>
  gtExtras::gt_theme_538()
```

広告費を表す `adient` 変数の観測値が全企業の中央値より大きいか否か、でダミー変数 `ad_dummy` を作成し、`ind_en` 変数と `ad_dummy` 変数のクロス集計表を作成します。

教科書を先取りしますが、`if_else()` 関数を使ってダミー変数を作成し、`count()` 関

ind_en	企業数
Air Transportation	8
Amusement Services	4
Bakery Products	1
Communication Services	2
Cosmetics & Toilet Goods	3
Department Stores	7
Foods, NEC	1
Home & Pre-Fabs	2
Hotels	5
Miscellaneous Services	27
Miscellaneous Wholesales	2
Motor Vehicles	4
Musical Instrument	1
Railroad (Major)	27
Railroad (Minor)	2
Real Estate - Sales	1
Retail Stores, NEC	35
Supermarket Chains	14
Trucking	1

数でクロス集計表を作成し、`gt` パッケージで表形式で表示します。`tidyverse` パッケージの `pivot_wider()` 関数を使って、クロス集計表が見やすくなるように、縦は産業名、横は広告費が中央値より大きいか否か、で表示するように変形しています。

```
firm2018 <- firm2018 |>
  mutate(
    ad_dummy = if_else(adint > median(adint, na.rm = TRUE), 1L, 0L)
  )
firm2018 %>%
  count(ind_en, ad_dummy) |>
  tidyverse::pivot_wider(names_from = ad_dummy, values_from = n,
  ~ values_fill = 0) |>
  gt::gt() |>
  gtExtras::gt_theme_538()
```

`table()` 関数を使うと簡単にクロス集計表が作れます。あえて `data.frame` 型のまま処理できる `dplyr::count()` 関数を使っています。そのため、データが矩形データのまま扱えるので、後で他の処理に使いやすくなるものの、表にすると見にくくなるので、`tidyverse::pivot_wider()` 関数で見やすく変形しています。

次に、カテゴリ変数ごとに処理を行いたい場合、例えば、産業分類ごとに売上高の平均値や標準偏差を計算したい場合は、`group_by()` 関数を使って、カテゴリ変数でグループ化してから、`summarize()` 関数で集計します。

ind_en	0	1
Air Transportation	4	4
Amusement Services	4	0
Bakery Products	0	1
Communication Services	1	1
Cosmetics & Toilet Goods	0	3
Department Stores	0	7
Foods, NEC	0	1
Home & Pre-Fabs	0	2
Hotels	5	0
Miscellaneous Services	17	10
Miscellaneous Wholesales	1	1
Motor Vehicles	0	4
Musical Instrument	0	1
Railroad (Major)	27	0
Railroad (Minor)	2	0
Real Estate - Sales	0	1
Retail Stores, NEC	11	24
Supermarket Chains	2	12
Trucking	1	0

```
# コード 4-39
firm2018 |>
  group_by(ind_en) |>
  summarize(
    obs = n(),
    sales_m = mean(sales),
    sales_sd = sd(sales),
    adint_m = mean(adint),
    adint_sd = sd(adint)
  ) |>
  gt::gt() |>
  gt::fmt_number(
    columns = c(sales_m, sales_sd, adint_m, adint_sd),
    decimals = 2
  ) |>
  gtExtras::gt_theme_538()
```

ind_en	OBS	sales_m	sales_sd	adint_m	adint_sd
Air Transportation	8	1,772,786.50	305,239.60	0.00	0.00
Amusement Services	4	298,137.50	263,017.35	0.00	0.00
Bakery Products	1	1,059,442.00	NA	0.01	NA
Communication Services	2	547,087.50	172,735.58	0.02	0.03
Cosmetics & Toilet Goods	3	140,669.33	100,063.48	0.11	0.05
Department Stores	7	843,248.29	348,818.99	0.02	0.01
Foods, NEC	1	504,153.00	NA	0.02	NA
Home & Pre-Fabs	2	4,143,505.00	0.00	0.01	0.00
Hotels	5	62,134.80	58,060.28	0.00	0.00
Miscellaneous Services	27	311,867.22	456,036.57	0.01	0.02
Miscellaneous Wholesales	2	176,520.00	52,778.45	0.02	0.03
Motor Vehicles	4	5,279,121.75	4,233,187.72	0.03	0.00
Musical Instrument	1	434,373.00	NA	0.04	NA
Railroad (Major)	27	1,302,920.52	1,037,834.05	0.00	0.00
Railroad (Minor)	2	260,502.00	0.00	0.00	0.00
Real Estate - Sales	1	1,861,195.00	NA	0.01	NA
Retail Stores, NEC	35	571,019.17	547,246.68	0.02	0.03
Supermarket Chains	14	4,335,164.07	3,511,346.59	0.01	0.01
Trucking	1	1,118,094.00	NA	0.00	NA

第 II 部

第 2 部 仮説検証型データ分析

第5章では基本統計学の復習を、第6章では回帰分析、第7章では回帰分析の応用としてダミー変数や交差項、変数変換について学習します。第8章では消費者選択を分析するための離散選択モデルとして、ロジットモデルとプロビットモデル、多項選択モデルを学びます。

第3章

第5章

```
# コード 5-1
pacman::p_load(tidyverse, readxl, pwr,knitr)

# コード 5-2
set.seed(442)
die <- 1:6
d <- sample(die, size = 1, replace = TRUE)
d
```

[1] 6

```
# コード 5-3
set.seed(352)
d1 <- sample(die, size = 10, replace = TRUE)
d2 <- sample(die, size = 10, replace = TRUE)
d3 <- sample(die, size = 10, replace = TRUE)
d_mean <- matrix(c(mean(d1), mean(d2), mean(d3)), nrow = 1)
colnames(d_mean) <- c("d1 の平均", "d2 の平均", "d3 の平均")
knitr::kable(d_mean, caption = "サイコロの標本平均比較", align = "ccc")
```

Table3.1: サイコロの標本平均比較

d1 の平均	d2 の平均	d3 の平均
3.2	3	2.4

```
# コード 5-4
set.seed(541)
d10 <- sample(die, size = 10, replace = TRUE)
```

```

d100 <- sample(die, size = 100, replace = TRUE)
d1000 <- sample(die, size = 1000, replace = TRUE)
d_lln <- matrix(c(mean(d10), mean(d100), mean(d1000)), nrow = 1)
colnames(d_lln) <- c("10 回試行の平均", "100 回試行の平均", "1,000 回試行
の平均")
knitr::kable(d_lln, caption = "サイコロの標本平均比較 2", align = "ccc")

```

Table3.2: サイコロの標本平均比較 2

10 回試行の平均	100 回試行の平均	1,000 回試行の平均
3	3.36	3.516

```

# コード 5-5
bulb <- c(
  1939.6, 1680.3, 1982.1, 2215.6,
  2092.5, 1928.9, 2003.8, 1955.5,
  1800.1, 1659.5, 2066.2, 2107.2,
  2085.5, 1878.6, 2007.6, 1816.1)
bulb_ci <- t.test(bulb) # t 検定の実施と格納
bulb_ci$conf.int # 信頼区間の出力 (デフォルトで 95 %信頼水準)

```

```

[1] 1868.890 2033.498
attr(,"conf.level")
[1] 0.95

```

```

# コード 5-6
qnorm(0.025, lower.tail = FALSE)

```

```
[1] 1.959964
```

```
# 標準正規分布における上側 2.5 %点の分位点を求める。
```

```

# コード 5-7
n <- length(bulb)
z <- qnorm(0.025, lower.tail = FALSE)
xbar <- mean(bulb)
sigma <- 180
# 信頼区間の計算
upper <- xbar + z * (sigma / sqrt(n))
lower <- xbar - z * (sigma / sqrt(n))

```

```
# 結果のまとめと出力
ci.bulb <- matrix(c(lower, upper), nrow = 1)
colnames(ci.bulb) <- c("ci.lower", "ci.upper")
knitr::kable(ci.bulb, caption = "Bulb data CI (95 %)", align = "cc")
```

Table3.3: Bulb data CI (95 %)

ci.lower	ci.upper
1862.995	2039.392

```
# コード 5-8
mean(bulb)
```

[1] 1951.194

```
# コード 5-9
t.test(bulb, alternative = "two.sided", mu = 1800)
```

One Sample t-test

```
data: bulb
t = 3.9155, df = 15, p-value = 0.001377
alternative hypothesis: true mean is not equal to 1800
95 percent confidence interval:
1868.890 2033.498
sample estimates:
mean of x
1951.194
```

```
# コード 5-10
n <- length(bulb)
z <- qnorm(0.025, lower.tail = FALSE)
xbar <- mean(bulb)
sigma <- 180
mu <- 1800
#Test statistic
Z <- (xbar - mu) / (sigma / sqrt(n))
Z
```

```
[1] 3.359861

# コード 5-11
library(tidyverse)
firmdata <- readxl::read_xlsx("data/MktRes_firmdata.xlsx")
firm2018 <- firmdata %>%
  filter(fyear == 2018) %>%
  mutate(ad_dummy = ifelse(adint > median(adint), 1, 0))
t.test(sales ~ ad_dummy, data = firm2018)
```

Welch Two Sample t-test

```
data: sales by ad_dummy
t = -3.3989, df = 85.686, p-value = 0.001029
alternative hypothesis: true difference in means between group 0 and group 1 is not equal to zero
95 percent confidence interval:
-1674283.1 -438496.1
sample estimates:
mean in group 0 mean in group 1
725009.7      1781399.3
```

```
# コード 5-12
var.test(sales ~ ad_dummy, data = firm2018, ratio = 1)
```

F test to compare two variances

```
data: sales by ad_dummy
F = 0.10863, num df = 74, denom df = 71, p-value < 2.2e-16
alternative hypothesis: true ratio of variances is not equal to 1
95 percent confidence interval:
0.06821636 0.17258882
sample estimates:
ratio of variances
0.1086276
```

```
# コード 5-13
```

```
# コード 5-14
```

```
est_n <- pwr.t.test(d = 0.8, power = 0.8, sig.level = 0.05)
est_n
```


Two-sample t test power calculation

```
n = 25.52458
d = 0.8
sig.level = 0.05
power = 0.8
alternative = two.sided
```

NOTE: n is number in *each* group

```
# コード 5-15
plot(est_n)
```

Two-sample t test power calculation



```
# コード 5-16
pwr.t.test(d = 0.8, n = 26, sig.level = 0.05)
```

Two-sample t test power calculation

```
n = 26
d = 0.8
```

```
sig.level = 0.05
power = 0.8074866
alternative = two.sided
```

NOTE: n is number in *each* group

第 4 章

第 6 章

```
pacman::p_load(tidyverse, readxl, GGally, knitr)


# コード 6-1
firmdata <- readxl::read_xlsx("data/MktRes_firmdata.xlsx")

# コード 6-2
library(tidyverse)
firmdata19 <- firmdata %>%
  filter(fyear == 2019)

# コード 6-3
# install.packages("GGally")

# コード 6-4
firmdata19 %>%
  select(sales, mkexp, emp, operating_profit) %>%
  GGally::ggpairs() + labs(title = "ggpairs example")
```

ggpairs example



```
# コード 6-5
ds1 <- firmdata19 %>%
  select(sales, mkexp, emp, operating_profit) %>%
  summary()
knitr::kable(ds1, align = "cccc")
```

sales	mkexp	emp	operating_profit
Min. : 11333	Min. :0.01137	Min. : 163	Min. :-40469
1st Qu.: 183525	1st Qu.:0.16714	1st Qu.: 3454	1st Qu.: 7743
Median : 464450	Median :0.25448	Median : 7826	Median : 23904
Mean :1199403	Mean :0.29868	Mean : 20249	Mean : 81088
3rd Qu.:1164243	3rd Qu.:0.37506	3rd Qu.: 24464	3rd Qu.: 63068
Max. :9878866	Max. :0.75650	Max. :160227	Max. :656163

```
# コード 6-6
reg1 <- lm(sales ~ emp, data = firmdata19)
coef(reg1)
```

(Intercept)	emp
22113.98050	58.14081

```
# コード 6-7
summary(reg1)
```

```

Call:
lm(formula = sales ~ emp, data = firmdata19)

Residuals:
    Min      1Q  Median      3Q     Max 
-1834902 -280228 -34549   136598  3292521 

Coefficients:
            Estimate Std. Error t value Pr(>|t|)    
(Intercept) 22113.980  89224.761   0.248   0.805    
emp          58.141     2.569   22.628 <2e-16 ***  
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

```

Residual standard error: 875800 on 144 degrees of freedom
 Multiple R-squared: 0.7805, Adjusted R-squared: 0.779
 F-statistic: 512 on 1 and 144 DF, p-value: < 2.2e-16

```

# コード 6-8
confint(reg1, level = 0.99)

            0.5 %      99.5 % 
(Intercept) -210798.52845 255026.48944
emp          51.43362    64.84799

```

```

# コード 6-9
reg2 <- lm(operating_profit ~ adv, data = firmdata19)
summary(reg2)

```

```

Call:
lm(formula = operating_profit ~ adv, data = firmdata19)

```

```

Residuals:
    Min      1Q  Median      3Q     Max 
-450526 -55552 -40672    -791  599084 

Coefficients:
            Estimate Std. Error t value Pr(>|t|)    
(Intercept) 5.708e+04  1.057e+04   5.401 2.68e-07 ***

```

```

adv           1.257e+00  2.159e-01   5.823 3.61e-08 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 117600 on 144 degrees of freedom
Multiple R-squared:  0.1906,    Adjusted R-squared:  0.185
F-statistic: 33.91 on 1 and 144 DF,  p-value: 3.613e-08

# コード 6-10
confint(reg2)

              2.5 %      97.5 %
(Intercept) 36189.311039 77968.894422
adv          0.830362  1.683719

# コード 6-11
reg3 <- lm(operating_profit ~ adv + temp + emp + labor_cost +
            + total_assets + rd, data = firmdata19)
summary(reg3)

Call:
lm(formula = operating_profit ~ adv + temp + emp + labor_cost +
    total_assets + rd, data = firmdata19)

Residuals:
    Min      1Q  Median      3Q      Max
-360544 -27618 -15279     3467  284094

Coefficients:
            Estimate Std. Error t value Pr(>|t|)
(Intercept) 2.209e+04  8.114e+03   2.723  0.00731 **
adv         -1.431e+00  2.954e-01  -4.845 3.34e-06 ***
temp        -1.878e+00  6.313e-01  -2.975  0.00346 **
emp         -1.510e+00  7.036e-01  -2.146  0.03358 *
labor_cost   8.808e-01  1.692e-01   5.207 6.76e-07 ***
total_assets 3.516e-02  5.840e-03   6.020 1.47e-08 ***
rd          1.385e+00  5.268e-01   2.629  0.00953 **
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

```

```
Residual standard error: 78940 on 139 degrees of freedom  
Multiple R-squared:  0.6479,   Adjusted R-squared:  0.6327  
F-statistic: 42.63 on 6 and 139 DF,  p-value: < 2.2e-16
```

```
# コード 6-12  
confint(reg3)  
  
              2.5 %      97.5 %  
(Intercept) 6048.51599480 3.813231e+04  
adv          -2.01511513 -8.470054e-01  
temp         -3.12602311 -6.298318e-01  
emp          -2.90144939 -1.190356e-01  
labor_cost    0.54637427  1.215313e+00  
total_assets   0.02361376  4.670793e-02  
rd            0.34334525  2.426472e+00
```


第 5 章

第 7 章

```

pacman::p_load(tidyverse, readxl, sjPlot, marginaleffects, car,
  modelsummary)
# コード 7-1
# library(tidyverse)
firmdata <- readxl::read_xlsx("data/MktRes_firmdata.xlsx")
firmdata19 <- firmdata %>%
  filter(fyear == 2019)
#産業名を特定したオブジェクト"Retail"の作成
retail <- c("Retail Stores, NEC", "Supermarket Chains",
           "Department Stores")
# Retail を使ったカテゴリー変数の作成
firmdata19 <- firmdata19 %>%
  mutate(format = ifelse(ind_en %in% retail, "Retail", "Other"))
#カテゴリーの頻度チェック
with(firmdata19, table(format))

```

```

format
Other Retail
 90      56

```

```

# コード 7-2
fit.d1 <- lm(op ~ mkexp + format, data = firmdata19)
summary(fit.d1)

```

Call:

```

lm(formula = op ~ mkexp + format, data = firmdata19)

```

Residuals:

Min	1Q	Median	3Q	Max
-0.095926	-0.031427	-0.008661	0.014345	0.261068

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	0.101694	0.008833	11.514	$< 2e-16$ ***
mkexp	-0.066003	0.024959	-2.644	0.009097 **
formatRetail	-0.031770	0.009303	-3.415	0.000831 ***

Signif. codes:	0	***	0.001	**
	0.01	*	0.05	.'
	0.1	'	1	

Residual standard error: 0.05368 on 143 degrees of freedom
 Multiple R-squared: 0.1379, Adjusted R-squared: 0.1258
 F-statistic: 11.44 on 2 and 143 DF, p-value: 2.469e-05

```
# コード 7-3
firmdata19 <- firmdata19 %>%
  mutate(retail = ifelse(format == "Retail", 1, 0))

# 確認
with(firmdata19, table(retail, format))
```

format	retail	Other	Retail
0	90	0	
1	0	56	

```
# コード 7-4
fit.d2 <- lm(op ~ mkexp + retail, data = firmdata19)
summary(fit.d2)
```

Call:

```
lm(formula = op ~ mkexp + retail, data = firmdata19)
```

Residuals:

Min	1Q	Median	3Q	Max
-0.095926	-0.031427	-0.008661	0.014345	0.261068

Coefficients:

Estimate	Std. Error	t value	Pr(> t)
----------	------------	---------	----------

```
(Intercept) 0.101694  0.008833 11.514 < 2e-16 ***
mkexp       -0.066003  0.024959 -2.644 0.009097 **
retail      -0.031770  0.009303 -3.415 0.000831 ***
---
Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

Residual standard error: 0.05368 on 143 degrees of freedom
 Multiple R-squared: 0.1379, Adjusted R-squared: 0.1258
 F-statistic: 11.44 on 2 and 143 DF, p-value: 2.469e-05

```
# コード 7-5
fit.d3 <- lm(op ~ mkexp * retail, data = firmdata19)
summary(fit.d3)
```

Call:

```
lm(formula = op ~ mkexp * retail, data = firmdata19)
```

Residuals:

Min	1Q	Median	3Q	Max
-0.100914	-0.027907	-0.006023	0.020847	0.254339

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	0.112780	0.009123	12.362	< 2e-16 ***
mkexp	-0.106801	0.026898	-3.971	0.000113 ***
retail	-0.099242	0.021752	-4.563	1.08e-05 ***
mkexp:retail	0.205666	0.060393	3.405	0.000859 ***

```
---
Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

Residual standard error: 0.0518 on 142 degrees of freedom
 Multiple R-squared: 0.203, Adjusted R-squared: 0.1862
 F-statistic: 12.06 on 3 and 142 DF, p-value: 4.461e-07


```
# コード 7-6
# install.packages("sjPlot")
```

```
# コード 7-7
# # library(sjPlot)
```

```

pred <- plot_model(fit.d3,
  type = "pred",
  terms = c("mkexp", "retail"),
  ci.lvl = .95) +
  labs(
    title = "Slope Analysis",
    subtitle = "(Predicted Values of Profitability with 95% Confidence
      Intervals)",
    x = "Marketing Expense",
    y = "Profitability"
  ) + scale_color_discrete(name = "Retail Dummy")
pred

```



```

# コード 7-8
Headphone07 <- readr::read_csv("data/headphone07.csv", na = ".")

```

```

#データフレームの確認
glimpse(Headphone07)

```

```

Rows: 221
Columns: 4
$ ID      <dbl> 1, 2, 3, 4, 5, 6, 7, 8, 9, 10, 11, 12, 13, 14, 15, 16, 17, 1-
$ sales    <dbl> 118.8377, 548.6312, 197.3075, 104.2657, 748.8251, 947.8850, ~

```

```
$ rd      <dbl> 404.0893, 252.1270, 444.3374, 407.5876, 841.7605, 336.8744, ~
$ promotion <dbl> 75.63163, 102.74572, 97.98040, 83.46613, 105.69250, 80.17476~

# コード 7-9
fit_int <- lm(sales ~ rd * promotion, data = Headphone07)
summary(fit_int)
```

Call:

```
lm(formula = sales ~ rd * promotion, data = Headphone07)
```

Residuals:

Min	1Q	Median	3Q	Max
-46.522	-12.861	-0.638	13.578	70.667

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)							
(Intercept)	2.033e+04	1.090e+02	186.5	<2e-16 ***							
rd	-5.187e+01	2.844e-01	-182.4	<2e-16 ***							
promotion	-1.914e+02	1.052e+00	-181.9	<2e-16 ***							
rd:promotion	4.979e-01	2.730e-03	182.4	<2e-16 ***							

Signif. codes:	0	'***'	0.001	'**'	0.01	'*'	0.05	'.'	0.1	' '	1

Residual standard error: 20.55 on 217 degrees of freedom

Multiple R-squared: 0.9935, Adjusted R-squared: 0.9934

F-statistic: 1.111e+04 on 3 and 217 DF, p-value: < 2.2e-16

```
# コード 7-10
Headphone07 <- Headphone07 %>%
  mutate(promotion_c = promotion - mean(promotion, na.rm = TRUE),
        rd_c = rd - mean(rd, na.rm = TRUE))

fit_int_c <- lm(sales ~ rd_c * promotion_c , data = Headphone07)
summary(fit_int_c)
```

Call:

```
lm(formula = sales ~ rd_c * promotion_c, data = Headphone07)
```

Residuals:

```

      Min       1Q   Median     3Q      Max
-46.522 -12.861  -0.638  13.578  70.667

Coefficients:
              Estimate Std. Error t value Pr(>|t|)
(Intercept) 382.27812  1.51459 252.40 <2e-16 ***
rd_c        -0.91767  0.01196 -76.75 <2e-16 ***
promotion_c  0.69039  0.03972 17.38 <2e-16 ***
rd_c:promotion_c 0.49792  0.00273 182.37 <2e-16 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

```

```

Residual standard error: 20.55 on 217 degrees of freedom
Multiple R-squared:  0.9935,    Adjusted R-squared:  0.9934
F-statistic: 1.111e+04 on 3 and 217 DF,  p-value: < 2.2e-16


```

```

# コード 7-11
leg = c("Mean - 1sd", "Mean", "Mean + 1sd")
int_fig1 <- plot_model(fit_int_c,
type = "int",
mdrt.values = "meansd",
ci.lvl = .9999999999) +
labs(
  title = "Predicted values of Sales(R&D * Promotion)",
  x = "R&D Investment",
  y = "Sales") +
scale_color_discrete(
  name = "Promotion level",
  labels = leg)
int_fig1

```


Predicted values of Sales(R&D * Promotion)




```
# コード 7-12
# install.packages("marginaleffects")

# コード 7-13
# library(marginaleffects)
int_fig2 <- plot_slopes(fit_int_c, variables = "rd_c",
  condition = "promotion_c", conf_level = .99999999) +
  labs(title = "Marginal effects of R&D on Sales",
    x = "Promotion", y = "Slope of R&D on Sales") +
  geom_hline(aes(yintercept = 0), linetype = "dashed")
int_fig2
```

Marginal effects of R&D on Sales



```
# コード 7-14
firmdata19 <- firmdata19 %>%
  mutate(mkexp_c = mkexp - mean(mkexp),
        asset_c = total_assets - mean(total_assets))
fit_int2 <- lm(op ~ mkexp_c * asset_c, data = firmdata19)
int_fig3 <- plot_slopes(fit_int2, variables = "mkexp_c",
                         condition = "asset_c", conf_level = 0.99) +
  geom_hline(aes(yintercept = 0), linetype = "dashed")
int_fig3
```



```
# コード 7-15
firmdata19 <- firmdata19 %>%
  mutate(adv = (adv - mean(adv)) / sd(adv),
        rd = (rd - mean(rd)) / sd(rd),
        ad_rd = adv + rd)
fit_linear <- lm(sales ~ adv + rd, data = firmdata19)
summary(fit_linear)
```

Call:

`lm(formula = sales ~ adv + rd, data = firmdata19)`

Residuals:

Min	1Q	Median	3Q	Max
-4357995	-463348	-236824	123663	2692251

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	1199403	74285	16.146	<2e-16 ***
adv	1632326	74996	21.766	<2e-16 ***
rd	29915	74996	0.399	0.691

Signif. codes:	0 '***'	0.001 '**'	0.01 '*'	0.05 '.'
	0.1 ' '	1		

```
Residual standard error: 897600 on 143 degrees of freedom
Multiple R-squared:  0.7711,    Adjusted R-squared:  0.7679
F-statistic: 240.8 on 2 and 143 DF,  p-value: < 2.2e-16
```

```
# コード 7-16
fit_comp <- lm(sales ~ adv + ad_rd, data = firmdata19)
summary(fit_comp)
```

Call:

```
lm(formula = sales ~ adv + ad_rd, data = firmdata19)
```

Residuals:

Min	1Q	Median	3Q	Max
-4357995	-463348	-236824	123663	2692251

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	1199403	74285	16.146	<2e-16 ***
adv	1602411	111739	14.341	<2e-16 ***
ad_rd	29915	74996	0.399	0.691

Signif. codes:	0 '***'	0.001 '**'	0.01 '*'	0.05 '.'
	0.1	' '	1	

```
Residual standard error: 897600 on 143 degrees of freedom
Multiple R-squared:  0.7711,    Adjusted R-squared:  0.7679
F-statistic: 240.8 on 2 and 143 DF,  p-value: < 2.2e-16
```

```
# コード 7-17
fit_prod <- lm(log(sales) ~ log(labor_cost) + log(ppent),
  data = firmdata19)

summary(fit_prod)
```

Call:

```
lm(formula = log(sales) ~ log(labor_cost) + log(ppent), data = firmdata19)
```

Residuals:

Min	1Q	Median	3Q	Max
-1.40821	-0.36129	-0.00933	0.38591	1.66673

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)							
(Intercept)	3.17129	0.31733	9.994	<2e-16 ***							
log(labor_cost)	0.53739	0.03679	14.605	<2e-16 ***							
log(ppent)	0.34588	0.02797	12.366	<2e-16 ***							

Signif. codes:	0	'***'	0.001	'**'	0.01	'*'	0.05	'. '	0.1	' '	1

Residual standard error: 0.5169 on 143 degrees of freedom

Multiple R-squared: 0.8747, Adjusted R-squared: 0.8729

F-statistic: 499.1 on 2 and 143 DF, p-value: < 2.2e-16

```
# コード 7-18
price <- readr::read_csv("data/price_data.csv")

fit_q <- lm(log(q) ~ log(p), data = price)
summary(fit_q)
```

Call:

lm(formula = log(q) ~ log(p), data = price)

Residuals:

Min	1Q	Median	3Q	Max
-1.11220	-0.13668	0.02804	0.16166	0.51039

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)							
(Intercept)	9.47781	0.08135	116.5	<2e-16 ***							
log(p)	-0.18008	0.01354	-13.3	<2e-16 ***							

Signif. codes:	0	'***'	0.001	'**'	0.01	'*'	0.05	'. '	0.1	' '	1

Residual standard error: 0.2309 on 998 degrees of freedom

Multiple R-squared: 0.1506, Adjusted R-squared: 0.1497

F-statistic: 176.9 on 1 and 998 DF, p-value: < 2.2e-16

```
# コード 7-19
# install.packages("car")
```

```
# コード 7-20
# library(car)
linearHypothesis(fit_q, c("log(p)= -1"))
```

Linear hypothesis test:

$\log(p) = -1$

Model 1: restricted model

Model 2: $\log(q) \sim \log(p)$

	Res.Df	RSS	Df	Sum of Sq	F	Pr(>F)
1	999	248.811				
2	998	53.225	1	195.59	3667.3 < 2.2e-16 ***	

						Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

```
# コード 7-21
# install.packages("modelsummary")

# コード 7-22
# library(modelsummary)
msummary(fit_int, statistic = 'conf.int')
```

```
# コード 7-23
msummary(fit_int, gof omit = "Log.Lik.|AIC|BIC|RMSE")
```

```
# コード 7-24
var_nam <- c("rd" = "R&D", "promotion" = "Promotion",
           "rd:promotion" = "R&D * Promotion",
           "rd_c" = "R&D_c", "promotion_c" = "Promotion_c",
           "rd_c:promotion_c" = "R&D_c * Promotion_c",
           "(Intercept)" = "定数項")
Int <- list()
Int[["Without centering"]] <- fit_int
Int[["With centering"]] <- fit_int_c

msummary(Int,
```

	(1)
(Intercept)	20 326.588
	[20 111.797, 20 541.378]
rd	-51.872
	[-52.433, -51.312]
promotion	-191.431
	[-193.505, -189.358]
rd × promotion	0.498
	[0.493, 0.503]
Num.Obs.	221
R2	0.994
R2 Adj.	0.993
AIC	1969.2
BIC	1986.2
Log.Lik.	-979.617
F	11 110.648
RMSE	20.36

	(1)
(Intercept)	20 326.588
	(108.978)
rd	-51.872
	(0.284)
promotion	-191.431
	(1.052)
rd × promotion	0.498
	(0.003)
Num.Obs.	221
R2	0.994
R2 Adj.	0.993
F	11 110.648

Table 5.1: Comparing Interaction Models

	Without centering	With centering
R&D	−51.872*** [−52.433, −51.312]	
Promotion	−191.431*** [−193.505, −189.358]	
R&D * Promotion	0.498*** [0.493, 0.503]	
R&D_c		−0.918*** [−0.941, −0.894]
Promotion_c		0.690*** [0.612, 0.769]
R&D_c * Promotion_c		0.498*** [0.493, 0.503]
定数項	20 326.588*** [20 111.797, 20 541.378]	382.278*** [379.293, 385.263]
Num.Obs.	221	221
R2	0.994	0.994
R2 Adj.	0.993	0.993
F	11 110.648	11 110.648

+ p <0.1, * p <0.05, ** p <0.01, *** p <0.001

Values in [] show 95% confidence intervals

```
coef_map = var_nam,
title = "Comparing Interaction Models",
notes = "Values in [ ] show 95% confidence intervals",
stars = TRUE,
statistic = 'conf.int', conf_level = .95,
gof.omit = "Log.Lik.|AIC|BIC|RMSE")
```

```
# コード 7-25
msummary(Int,
          title = "Comparing Interaction Models",
```

Table 5.2: Comparing Interaction Models

	Without centering	With centering
(Intercept)	20 326.588*** [20 111.797, 20 541.378]	382.278*** [379.293, 385.263]
rd	-51.872*** [-52.433, -51.312]	
promotion	-191.431*** [-193.505, -189.358]	
rd × promotion	0.498*** [0.493, 0.503]	
rd_c		-0.918*** [-0.941, -0.894]
promotion_c		0.690*** [0.612, 0.769]
rd_c × promotion_c		0.498*** [0.493, 0.503]
Num.Obs.	221	221
R2	0.994	0.994
R2 Adj.	0.993	0.993
F	11 110.648	11 110.648

+ p <0.1, * p <0.05, ** p <0.01, *** p <0.001

Values in [] show 95% confidence intervals

```
notes = "Values in [ ] show 95% confidence intervals",
stars = TRUE,
statistic = 'conf.int', conf_level = .95,
gof.omit = "Log.Lik.|AIC|BIC|RMSE",
output = "latex")
```


第 6 章

第 8 章

```
pacman::p_load(tidyverse, readxl, modelsummary, mfx, DescTools,
  ↵  mlogit)
```

```
# コード 8-1
df1 <- data.frame(
  Y = c(0, 0, 0, 0, 0, 1, 1, 1, 1),
  X = c(3.4, 5.22, 7.06, 2.81, 4.11, 10.34, 13.67, 15.99, 9.09)
)
lpm1 <- lm(Y ~ X, data = df1)
pred_lpm1 <- predict(lpm1)
pred_lpm1
```

1	2	3	4	5	6
-0.006342894	0.173357681	0.355032986	-0.064597476	0.063760077	0.678888967
7	8	9			
1.007681776	1.236750640	0.555468243			

```
# コード 8-2
choice_df <- readxl::read_xlsx("data/choice_data.xlsx")
head(choice_df)
```

```
# A tibble: 6 x 6
  y1     y2     p1     p2     a1     a2
  <dbl> <dbl> <dbl> <dbl> <dbl> <dbl>
1     1     0 10.7  16.8      0     1
2     0     1 11.6   9.15      1     0
3     1     0  8.97  9.31      1     0
4     1     0  4.62  8.03      0     0
5     1     0  7.81 19.2       1     1
```

```
6      1      0  7.49  8.84      0      0
```

```
# コード 8-3
probit1 <- glm(y1 ~ p1 + a1,
                 family = binomial(link = probit),
                 data = choice_df)
summary(probit1)
```

Call:

```
glm(formula = y1 ~ p1 + a1, family = binomial(link = probit),
     data = choice_df)
```

Coefficients:

	Estimate	Std. Error	z value	Pr(> z)
(Intercept)	2.04117	0.22350	9.133	< 2e-16 ***
p1	-0.24720	0.02213	-11.171	< 2e-16 ***
a1	0.62763	0.08656	7.251	4.13e-13 ***

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

(Dispersion parameter for binomial family taken to be 1)

Null deviance: 1384.5 on 999 degrees of freedom
 Residual deviance: 1205.5 on 997 degrees of freedom
 AIC: 1211.5

Number of Fisher Scoring iterations: 3

```
# コード 8-4
ols1 <- lm(y1 ~ p1 + a1,
            data = choice_df)
logit1 <- glm(y1 ~ p1 + a1,
                family = binomial(link = logit),
                data = choice_df)
models <- list()
models[["Linear probability model"]] <- ols1
models[["Probit model"]] <- probit1
models[["Logit model"]] <- logit1
modelsummary(models,
```

Table 6.1: モデル比較

	Linear probability model	Probit model	Logit model
(Intercept)	1.196*** (0.065)	2.041*** (0.212)	3.332*** (0.361)
p1	-0.085*** (0.006)	-0.247*** (0.021)	-0.404*** (0.036)
a1	0.221*** (0.029)	0.628*** (0.087)	1.035*** (0.145)
Num.Obs.	1000	1000	1000

+ p <0.1, * p <0.05, ** p <0.01, *** p <0.001

Values in [] show robust standard errors

```
title = "モデル比較",
notes = "Values in [ ] show robust standard errors",
stars = TRUE,
statistic = "std.error",
vcov = "robust",
gof_map = "nobs")
```

```
# 適合度指標において、サンプルサイズ ("nobs") のみ表示するという指示
```

```
# コード 8-5
# Average Marginal Effects (限界効果の平均)
probit1_ame <- probitmfx(y1 ~ p1 + a1,
                           data = choice_df, atmean = FALSE)
probit1_ame
```

Call:

```
probitmfx(formula = y1 ~ p1 + a1, data = choice_df, atmean = FALSE)
```

Marginal Effects:

dF/dx	Std. Err.	z	P> z
p1	-0.0847786	0.0060787	-13.9469 < 2.2e-16 ***
a1	0.2188866	0.0289816	7.5526 4.266e-14 ***

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1			

dF/dx is for discrete change for the following variables:

```
[1] "a1"

# コード 8-7
# Marginal Effects at Mean (平均値における限界効果)
probit1_mem <- probitmfx(y1 ~ p1 + a1,
                           data = choice_df, atmean = TRUE)
probit1_mem

Call:
probitmfx(formula = y1 ~ p1 + a1, data = choice_df, atmean = TRUE)

Marginal Effects:
      dF/dx  Std. Err.      z   P>|z|
p1 -0.0984235  0.0088074 -11.1750 < 2.2e-16 ***
a1  0.2446609  0.0324366    7.5427 4.602e-14 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

dF/dx is for discrete change for the following variables:

```
[1] "a1"

# コード 8-8
marginal <- c(
  "p1 marginal" = "p1",
  "a1 marginal" = "a1"
)

marg_model <- list(
  "(1) Probit_AME" <- probit1_ame,
  "(2) Probit_MEM" <- probit1_mem
)

marg_sum <- modelsummary(
  marg_model,
  statistic = "std.error",
  coef_map = marginal,
```

Table 6.2: 限界効果サマリー

	(1)	(2)
p1	-0.085*** (0.006)	-0.098*** (0.009)
a1	0.219*** (0.029)	0.245*** (0.032)
Num.Obs.	1000	1000
Marginal effect type	Average Marginal Effect	Marginal Effect at Mean

+ p <0.1, * p <0.05, ** p <0.01, *** p <0.001

```

stars = TRUE,
shape = term:component ~ model,
add_rows = data.frame("Marginal effect type",
                      "Average Marginal Effect",
                      "Marginal Effect at Mean"),
title = "限界効果サマリー",
gof_map = "nobs"
)
marg_sum

```

```

# コード 8-9
DescTools::PseudoR2(probit1)

```

```

McFadden
0.1293345

```

```

# コード 8-10

# 価格差変数作成
choice_df <- choice_df %>%
  mutate(p_ratio = p1 - p2)

probit2 <- glm(y1 ~ p_ratio + a1 + a2,
                 family = binomial(link = probit),
                 data = choice_df)
summary(probit2)

```

```

Call:
glm(formula = y1 ~ p_ratio + a1 + a2, family = binomial(link = probit),
     data = choice_df)

Coefficients:
              Estimate Std. Error z value Pr(>|z|)
(Intercept) -0.54634   0.07756 -7.044 1.87e-12 ***
p_ratio      -0.22180   0.01524 -14.559 < 2e-16 ***
a1            0.66314   0.09162  7.238 4.55e-13 ***
a2            -0.32291   0.09884 -3.267  0.00109 **
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

(Dispersion parameter for binomial family taken to be 1)

Null deviance: 1384.5 on 999 degrees of freedom
Residual deviance: 1066.9 on 996 degrees of freedom
AIC: 1074.9

Number of Fisher Scoring iterations: 4

```

```
# コード 8-11
DescTools::PseudoR2(probit2)
```

McFadden
0.229384

```
# コード 8-12
probit2_ame <- probitmfx(y1 ~ p_ratio + a1 + a2,
                           data = choice_df, atmean = FALSE)
probit2_ame
```

```
Call:
probitmfx(formula = y1 ~ p_ratio + a1 + a2, data = choice_df,
           atmean = FALSE)
```

Marginal Effects:

	dF/dx	Std. Err.	z	P> z
p_ratio	-0.0669199	0.0029405	-22.7581	< 2.2e-16 ***
a1	0.2036848	0.0270475	7.5306	5.049e-14 ***
a2	-0.0969891	0.0291848	-3.3233	0.0008897 ***

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

dF/dx is for discrete change for the following variables:

```
[1] "a1" "a2"
```

```
# コード 8-13
```

```
data(Cracker, package = "mlogit")
head(Cracker, n = 20)
```

	<code>id</code>	<code>disp.sunshine</code>	<code>disp.keebler</code>	<code>disp.nabisco</code>	<code>disp.private</code>	<code>feat.sunshine</code>
1	1	0	0	0	0	0
2	1	0	0	0	0	0
3	1	1	0	0	0	0
4	1	0	0	0	0	0
5	1	0	0	0	0	0
6	1	0	0	0	0	0
7	1	0	0	1	0	0
8	1	0	0	1	0	0
9	1	0	0	1	0	0
10	1	1	0	1	0	0
11	1	0	0	1	0	0
12	1	0	0	0	0	0
13	1	1	0	0	0	0
14	1	0	1	1	0	0
15	1	0	0	0	0	0
16	1	0	0	1	0	0
17	2	0	0	0	0	0
18	2	1	0	1	0	1
19	2	1	0	0	0	1
20	2	1	0	0	0	0
		<code>feat.keebler</code>	<code>feat.nabisco</code>	<code>feat.private</code>	<code>price.sunshine</code>	<code>price.keebler</code>
1		0	0	0	98	88
2		0	0	0	99	109
3		0	0	0	49	109
4		0	0	0	103	109
5		0	0	0	109	109
6		0	0	0	89	109
7		0	0	0	109	109

8	0	0	0	109	119
9	0	0	0	109	121
10	0	0	0	79	121
11	0	0	0	109	113
12	0	0	0	109	121
13	0	0	0	89	121
14	0	0	0	109	109
15	0	0	0	109	109
16	0	0	0	129	104
17	0	0	0	79	99
18	0	0	0	69	105
19	0	0	0	79	125
20	0	0	0	79	125
	price.nabisco	price.private	choice		
1	120		71 nabisco		
2	99		71 nabisco		
3	109		78 sunshine		
4	89		78 nabisco		
5	119		64 nabisco		
6	119		84 nabisco		
7	129		78 sunshine		
8	129		78 nabisco		
9	109		78 nabisco		
10	109		78 nabisco		
11	109		96 nabisco		
12	99		86 nabisco		
13	99		86 nabisco		
14	129		96 nabisco		
15	129		79 nabisco		
16	129		96 nabisco		
17	69		69 nabisco		
18	89		65 sunshine		
19	106		69 sunshine		
20	106		69 sunshine		

```
# コード 8-14
cracker <- mlogit.data(Cracker, choice = "choice", shape = "wide",
                        varying = c(2:13))
head(cracker, n = 20)
```

~~~~~

first 20 observations out of 13168

~~~~~

	id	choice	alt	disp	feat	price	chid	idx
1	1	FALSE	keebler	0	0	88	1	1:bler
2	1	TRUE	nabisco	0	0	120	1	1:isco
3	1	FALSE	private	0	0	71	1	1:vate
4	1	FALSE	sunshine	0	0	98	1	1:hine
5	1	FALSE	keebler	0	0	109	2	2:bler
6	1	TRUE	nabisco	0	0	99	2	2:isco
7	1	FALSE	private	0	0	71	2	2:vate
8	1	FALSE	sunshine	0	0	99	2	2:hine
9	1	FALSE	keebler	0	0	109	3	3:bler
10	1	FALSE	nabisco	0	0	109	3	3:isco
11	1	FALSE	private	0	0	78	3	3:vate
12	1	TRUE	sunshine	1	0	49	3	3:hine
13	1	FALSE	keebler	0	0	109	4	4:bler
14	1	TRUE	nabisco	0	0	89	4	4:isco
15	1	FALSE	private	0	0	78	4	4:vate
16	1	FALSE	sunshine	0	0	103	4	4:hine
17	1	FALSE	keebler	0	0	109	5	5:bler
18	1	TRUE	nabisco	0	0	119	5	5:isco
19	1	FALSE	private	0	0	64	5	5:vate
20	1	FALSE	sunshine	0	0	109	5	5:hine

~~~ indexes ~~~~

|    | chid | alt      |
|----|------|----------|
| 1  | 1    | keebler  |
| 2  | 1    | nabisco  |
| 3  | 1    | private  |
| 4  | 1    | sunshine |
| 5  | 2    | keebler  |
| 6  | 2    | nabisco  |
| 7  | 2    | private  |
| 8  | 2    | sunshine |
| 9  | 3    | keebler  |
| 10 | 3    | nabisco  |
| 11 | 3    | private  |
| 12 | 3    | sunshine |

```

13    4 keebler
14    4 nabisco
15    4 private
16    4 sunshine
17    5 keebler
18    5 nabisco
19    5 private
20    5 sunshine
indexes: 1, 2

# コード 8-15
ml_cracker <- mlogit(choice ~ price | 1 | disp + feat, probit = FALSE,
                        data = cracker)

summary(ml_cracker)

```

Call:  
`mlogit(formula = choice ~ price | 1 | disp + feat, data = cracker,`  
`probit = FALSE, method = "nr")`

Frequencies of alternatives:choice  
keebler nabisco private sunshine  
0.068651 0.544350 0.314399 0.072600

nr method  
5 iterations, 0h:0m:0s  
g'(-H)^-1g = 0.000258  
successive function values within tolerance limits

Coefficients :

|                      | Estimate   | Std. Error | z-value  | Pr(> z )      |
|----------------------|------------|------------|----------|---------------|
| (Intercept):nabisco  | 2.0011226  | 0.0831336  | 24.0712  | < 2.2e-16 *** |
| (Intercept):private  | 0.3193793  | 0.1238052  | 2.5797   | 0.0098888 **  |
| (Intercept):sunshine | -0.5435987 | 0.1139407  | -4.7709  | 1.834e-06 *** |
| price                | -0.0300966 | 0.0021082  | -14.2761 | < 2.2e-16 *** |
| disp:keebler         | 0.2999316  | 0.2070369  | 1.4487   | 0.1474251     |
| disp:nabisco         | 0.1011111  | 0.0773633  | 1.3070   | 0.1912249     |
| disp:private         | -0.2244555 | 0.1495236  | -1.5011  | 0.1333199     |
| disp:sunshine        | 0.4818670  | 0.1672400  | 2.8813   | 0.0039605 **  |

```

feat:keebler      0.6678542  0.2581732   2.5868  0.0096859 **
feat:nabisco     0.6047773  0.1404077   4.3073  1.653e-05 ***
feat:private      0.1726981  0.2004446   0.8616  0.3889213
feat:sunshine    0.8304895  0.2340938   3.5477  0.0003886 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

```

Log-Likelihood: -3333.8  
McFadden R<sup>2</sup>: 0.052798  
Likelihood ratio test : chisq = 371.66 (p.value = < 2.22e-16)

```

# コード 8-16
# パラメータの推定値 (beta) の抽出
beta <- probit2$coefficients

# パラメータ beta と説明変数の線形結合を作成 (beta_0 は定数項なので 1 をかかる)
est_probit2 <- cbind(1, choice_df$p_ratio, choice_df$a1,
                      choice_df$a2) %*% beta

# pnorm によって標準正規分布の分布関数による計算を実行する。
# 製品 1(c1) を選ぶ確率の予測値
pred_probit_c1 <- pnorm(est_probit2)
mean(pred_probit_c1)

```

[1] 0.4789384

```

# コード 8-17
# ロジットモデルの場合
logit2 <- glm(y1 ~ p_ratio + a1 + a2,
                family = binomial(link = logit),
                data = choice_df)

beta_logit <- logit2$coefficients
est_logit2 <- cbind(1, choice_df$p_ratio, choice_df$a1,
                      choice_df$a2) %*% beta_logit
pred_logit_c1 <- (exp(est_logit2)) / (1 + exp(est_logit2))
mean(pred_logit_c1)

```

[1] 0.479

```
# コード 8-18
choice_df_v <- choice_df %>%
  mutate(p1_v = p1 - 1,
        p_ratio_v = p1_v - p2)
est_probit_v <- cbind(1, choice_df_v$p_ratio_v, choice_df_v$a1,
                      choice_df_v$a2) %*% beta

# pnorm によって標準正規分布の分布関数による計算を実行する。
# 製品 1(c1) を選ぶ確率の予測値
pred_probit_v <- pnorm(est_probit_v)
mean(pred_probit_v)
```

[1] 0.5459071

## 第 III 部

### 第 3 部 探索型データ分析



第 9 章では観察重視アプローチ、第 10 章ではセグメントとクラスター分析を、第 11 章では探索的因子分析、第 12 章では価格感応度測定 (PSM) について学びます。第 9 章は観察重視アプローチと理論重視アプローチを学習しますが、R コードが出てこないので、ここでは割愛します。



## 第 7 章

# 第 10 章セグメントとクラスター分析

クラスター分析 (cluster analysis) は、観測値をいくつかのグループに分ける手法です。ここでは、階層的クラスター分析と非階層的クラスター分析 (K-means 法) を学習します。

## 7.1 階層的クラスター分析

データの中から類似している観測値を段階的にクラスターとしてまとめて、最終的に 1 つのクラスターになるまで繰り返す方法です。類似度は距離で測定され、距離が近いほど類似しているとみなされます。距離概念として、

- ユークリッド距離 (Euclidean distance)
- マンハッタン距離 (Manhattan distance)
- マハラノビス距離 (Mahalanobis distance)

などがあります。デンドログラム (dendrogram) という樹形図を使って、クラスターの結合過程を視覚的に表現します。

2023 年実施の消費者調査アンケートデータを使って、階層的クラスター分析を実行してみます。必要なパッケージを読み込みます。

- tidyverse: データ操作と可視化
- readxl: Excel データの読み込み
- cluster: クラスター分析
- factoextra: クラスター分析の可視化
- ggrepel: グラフ上のラベル配置
- useful: 便利な関数群

そしてデータを読み込みます。`read_xlsx()` 関数の引数として、

- path: データファイルのパスとファイル名
- sheet: 読み込むシート名
- na: 欠損値を表す文字列

```

pacman::p_load(tidyverse, readxl, cluster, factoextra, ggrepel,
  ↵ useful)
# コード 10-1
df_cons <- read_xlsx(
  path = "data/回答データ【消費者調査 2023 年度下期調査】.xlsx",
  sheet = "回答データ【共通調査 2023 年度下期】",
  na = " "
)

```

読み込んだデータを `str()` で確認します。

```

df_cons |>str()

tibble [5,364 x 992] (S3:tbl_df/tbl/data.frame)
$ 2023年下期no: num [1:5364] 1 2 3 4 7 8 9 10 11 12 ...
$ 県番号      : num [1:5364] 13 13 27 14 13 13 14 11 25 14 ...
$ 地域分類     : num [1:5364] 3 3 6 3 3 3 3 3 6 3 ...
$ 性別         : num [1:5364] 2 1 1 1 1 1 2 2 1 2 ...
$ 年齢         : num [1:5364] 38 42 25 26 30 33 52 53 36 26 ...
$ 年齢階層     : num [1:5364] 3 4 2 2 3 3 5 5 3 2 ...
$ 性年代       : num [1:5364] 11 4 2 2 3 3 13 13 3 10 ...
$ 結婚有無     : num [1:5364] 2 2 1 1 1 1 1 2 1 2 ...
$ q1           : num [1:5364] 2 1 1 1 1 1 2 2 1 2 ...
$ q2t          : num [1:5364] 38 42 25 26 30 33 52 53 36 26 ...
$ q3           : num [1:5364] 13 13 27 14 13 13 14 11 25 14 ...
$ q4           : num [1:5364] 1 1 2 2 2 2 2 1 2 1 ...
$ q5           : num [1:5364] 8 2 7 3 3 3 3 8 4 4 ...
$ q6           : num [1:5364] 2 2 3 4 1 1 1 2 1 2 ...
$ q7_1          : num [1:5364] 1 8 2 10 3 5 6 1 5 5 ...
$ q7_2          : num [1:5364] 4 9 3 10 NA NA NA 4 NA 8 ...
$ q8           : num [1:5364] 4 4 2 5 2 2 4 1 4 4 ...
$ q9           : num [1:5364] 1 4 1 2 2 4 1 5 6 5 ...
$ q10          : num [1:5364] 4 7 2 7 1 1 3 5 NA 5 ...
$ q11_1         : num [1:5364] 5 4 1 3 4 2 4 2 3 2 ...
$ q11_2         : num [1:5364] 4 5 2 3 4 2 3 2 3 2 ...
$ q11_3         : num [1:5364] 4 5 2 3 3 2 4 2 3 2 ...
$ q11_4         : num [1:5364] 4 4 3 3 4 2 4 2 3 2 ...
$ q11_5         : num [1:5364] 4 4 3 4 4 2 4 2 3 2 ...
$ q11_6         : num [1:5364] 4 4 3 3 3 2 4 2 3 2 ...
$ q11_7         : num [1:5364] 4 5 2 3 4 1 4 2 3 2 ...

```

```
$ q11_8      : num [1:5364] 4 4 3 3 4 1 3 2 3 2 ...
$ q11_9      : num [1:5364] 4 4 3 2 4 2 5 2 3 3 ...
$ q11_10     : num [1:5364] 4 5 4 3 3 2 3 2 3 3 ...
$ q11_11     : num [1:5364] 4 5 3 3 4 2 4 2 3 2 ...
$ q11_12     : num [1:5364] 4 4 3 3 3 1 4 2 3 2 ...
$ q11_13     : num [1:5364] 4 4 2 3 3 1 3 3 3 2 ...
$ q11_14     : num [1:5364] 4 4 2 3 4 1 4 4 3 2 ...
$ q11_15     : num [1:5364] 4 4 3 4 4 2 3 4 3 2 ...
$ q11_16     : num [1:5364] 4 4 3 3 4 2 5 3 3 2 ...
$ q11_17     : num [1:5364] 4 5 3 3 5 2 4 3 3 2 ...
$ q11_18     : num [1:5364] 4 4 2 3 4 2 4 3 3 3 ...
$ q11_19     : num [1:5364] 4 5 2 3 5 2 5 3 3 4 ...
$ q11_20     : num [1:5364] 4 4 3 3 4 2 4 3 3 2 ...
$ q11_21     : num [1:5364] 4 4 3 3 5 2 3 3 3 4 ...
$ q11_22     : num [1:5364] 4 4 3 3 4 2 3 3 3 3 ...
$ q11_23     : num [1:5364] 4 4 4 3 4 1 5 3 3 2 ...
$ q11_24     : num [1:5364] 4 5 3 3 5 1 4 3 3 2 ...
$ q11_25     : num [1:5364] 4 4 3 4 4 1 4 3 3 2 ...
$ q12_1      : num [1:5364] 2 2 3 4 1 3 3 2 3 2 ...
$ q12_2      : num [1:5364] 2 1 4 3 2 3 2 5 3 4 ...
$ q12_3      : num [1:5364] 2 2 3 3 1 4 2 5 3 4 ...
$ q12_4      : num [1:5364] 2 2 3 3 1 4 2 5 3 4 ...
$ q12_5      : num [1:5364] 2 1 4 3 2 5 3 5 3 4 ...
$ q13_1      : num [1:5364] 2 2 3 4 2 4 2 2 2 2 ...
$ q13_2      : num [1:5364] 2 2 3 3 2 5 2 2 2 3 ...
$ q13_3      : num [1:5364] 2 1 3 3 2 5 2 3 2 2 ...
$ q13_4      : num [1:5364] 4 5 3 3 5 1 3 3 1 2 ...
$ q14_1      : num [1:5364] 4 3 3 3 3 2 2 4 3 2 ...
$ q14_2      : num [1:5364] 4 4 3 3 3 2 2 4 3 3 ...
$ q14_3      : num [1:5364] 4 4 3 3 3 1 2 4 3 4 ...
$ q14_4      : num [1:5364] 4 4 3 3 2 1 4 4 3 3 ...
$ q14_5      : num [1:5364] 4 4 3 3 3 2 5 4 3 3 ...
$ q14_6      : num [1:5364] 4 5 2 2 3 2 4 4 4 4 ...
$ q14_7      : num [1:5364] 4 4 3 3 4 2 2 3 3 3 ...
$ q14_8      : num [1:5364] 4 5 3 4 3 2 2 3 3 3 ...
$ q14_9      : num [1:5364] 4 4 3 3 5 2 3 3 3 4 ...
$ q14_10     : num [1:5364] 4 5 2 3 5 1 4 3 3 4 ...
$ q14_11     : num [1:5364] 4 5 3 3 4 1 2 3 4 2 ...
$ q14_12     : num [1:5364] 4 4 3 3 3 1 4 3 3 3 ...
```

```

$ q14_13      : num [1:5364] 4 4 3 3 4 2 4 3 3 4 ...
$ q14_14      : num [1:5364] 4 4 3 3 3 2 2 3 3 3 ...
$ q14_15      : num [1:5364] 4 5 3 3 3 2 4 3 4 3 ...
$ q14_16      : num [1:5364] 4 5 2 3 4 1 2 3 3 3 ...
$ q14_17      : num [1:5364] 4 5 2 3 4 1 4 4 4 3 ...
$ q15_1       : num [1:5364] 1 2 3 3 2 4 3 3 3 2 ...
$ q15_2       : num [1:5364] 2 2 3 3 3 5 2 3 3 4 ...
$ q15_3       : num [1:5364] 2 2 3 3 2 5 2 3 3 3 ...
$ q15_4       : num [1:5364] 2 1 3 2 3 5 2 3 3 2 ...
$ q15_5       : num [1:5364] 2 2 3 3 3 4 3 3 3 2 ...
$ q15_6       : num [1:5364] 2 2 3 2 2 4 1 3 2 3 ...
$ q15_7       : num [1:5364] 2 2 5 2 3 4 2 3 3 3 ...
$ q16_1       : num [1:5364] 2 1 3 4 3 3 3 2 4 2 ...
$ q16_2       : num [1:5364] 2 2 3 3 3 4 4 3 4 2 ...
$ q16_3       : num [1:5364] 2 2 3 3 3 4 2 3 3 3 ...
$ q16_4       : num [1:5364] 2 2 3 3 3 4 3 3 3 3 ...
$ q17_1.01    : num [1:5364] 0 1 0 0 1 1 0 0 0 1 ...
$ q17_1.02    : num [1:5364] 0 1 0 0 0 0 0 0 0 0 ...
$ q17_1.03    : num [1:5364] 0 0 0 0 0 0 0 0 0 1 ...
$ q17_1.04    : num [1:5364] 0 0 0 0 0 0 0 0 0 0 ...
$ q17_1.05    : num [1:5364] 0 0 0 0 0 0 0 0 0 0 ...
$ q17_1.06    : num [1:5364] 0 0 0 0 0 0 0 0 0 0 ...
$ q17_1.07    : num [1:5364] 0 0 0 0 0 0 0 0 0 0 ...
$ q17_1.08    : num [1:5364] 0 0 0 0 0 0 0 0 0 0 ...
$ q17_1.09    : num [1:5364] 0 0 0 0 0 0 0 0 0 0 ...
$ q17_1.10    : num [1:5364] 0 0 0 0 1 0 0 0 0 0 ...
$ q17_1.11    : num [1:5364] 0 0 0 0 0 0 0 1 0 0 ...
$ q17_1.12    : num [1:5364] 0 0 0 0 0 0 0 0 0 0 ...
$ q17_1.13    : num [1:5364] 0 0 0 0 1 0 0 1 0 0 ...
$ q17_1.14    : num [1:5364] 0 0 0 0 0 0 0 0 0 0 ...
$ q17_1.15    : num [1:5364] 0 0 0 0 0 0 0 0 0 0 ...
$ q17_1.16    : num [1:5364] 0 0 0 0 0 0 0 0 0 0 ...
$ q17_1.17    : num [1:5364] 0 1 0 0 1 0 0 0 0 0 ...
$ q17_1.18    : num [1:5364] 0 0 0 0 0 0 0 0 0 0 ...

[list output truncated]

```

992変数、5364観測値からなるデータを読み込みました。東京都(13)と兵庫県(28)の回答者を対象に、ブランド志向性(q12\_4)と価格志向性(q13\_3)の2変数を使ってクラスター分析を実行します。

教科書では、カテゴリー変数の数値を文字列に変換するために、`case_when()`関数を

使っていますが、この処理だと変数の型が文字列となり、カテゴリー変数として R が認識しなくなります。そこでここでは、`factor()` 関数を使って、変数の型を因子型に変換し、ラベルを付与する方法を採用します。

```
# 東京と兵庫の県番号リスト作成
ken_number <- c(13, 28)

# 回答者と項目を抽出
df_cons <- df_cons |>
  select(県番号, 性別, 年齢, 結婚有無, q12_4, q13_3) |>
  filter( # 東京と兵庫を抽出し、欠損値を除去
    県番号 %in% ken_number, # 東京と兵庫の回答者
    q12_4 != 999, # 欠損値は 999
    q13_3 != 999
  ) |>
  mutate(
    q12_4 = 6 - q12_4, # 尺度を反転
    q13_3 = 6 - q13_3, # 尺度を反転
    # 県番号, 性別, 結婚有無を因子型に変換して、ラベルを付与
    Pref = factor(県番号,
      levels = c(13, 28),
      labels = c("Tokyo", "Hyogo")
    ),
    Gender = factor( # 性別を因子型の Gender に変換
      性別,
      levels = c(1, 2),
      labels = c("Male", "Female")
    ),
    MaritalSt. = factor( # 結婚有無を因子型の MaritalSt. に変換
      結婚有無,
      levels = c(1, 2),
      labels = c("Married", "Not Married")
    )
  )
```

クラスター分析を実行する関数の引数は数値データのみである必要があるので、`select()` で必要な変数だけを抽出し、オブジェクト `clus_cons` に格納します。

`agnes()` 関数を使って階層的クラスター分析を実行します。引数として、

- `clus_cons`: クラスター分析対象データ
- `metric`: 距離尺度

- `method`: クラスター結合方法
- `stand`: 変数の標準化


を指定します。実行結果を `Hier1` に格納し, `pltree()` 関数でデンドログラムを作成します。

```
clus_cons <- df_cons |> select(q12_4, q13_3)

Hier1 <- agnes(
  clus_cons, # クラスター分析対象データ
  metric = "euclidian", # 距離尺度
  method = "ward", # クラスター結合方法
  stand = TRUE # 変数の標準化
)

pltree(Hier1) # デンドログラムの作成
```

| `agnes(x = clus_cons, metric = "euclidian", stand = TRUE`



`clus_cons`  
`agnes (*, "ward")`


次に, `hclust()` 関数を使って階層的クラスター分析を実行します。

```
alt_Hier <- clus_cons |>
  dist("euclidian") |> # ユークリッド距離の計算
  hclust("ward.D") # ウォード法による階層的クラスター分析
```


```
alt_Hier |>
  fviz_dend(
    k = 4, # クラスター数
```

```
rect = TRUE, # クラスター枠の表示  
rect_border = TRUE # クラスター枠の色表示  
)
```


Cluster Dendrogram



```
# コード 10-5  
fviz_nbclust(  
  clus_cons, # クラスター分析対象データ  
  kmeans, # k-means 法  
  method = "wss" # クラスター内変動の総和  
)
```



```
alt_Hier |>
  fviz_dend(
    k = 5, # クラスター数
    rect = TRUE, # クラスター枠の表示
    rect_border = TRUE # クラスター枠の色表示
  )
```



```
# 亂数の種を設定
set.seed(343)

# k-means 法による非階層的クラスター分析
K_shopping <- kmeans(clus_cons, 5)
K_shopping

K-means clustering with 5 clusters of sizes 80, 298, 760, 592, 243

Cluster means:
q12_4      q13_3
1 1.000000 3.850000
2 2.738255 4.218121
3 3.417105 2.792105
4 2.552365 1.876689
5 4.300412 4.222222

Clustering vector:
[1] 5 5 5 4 3 3 3 4 2 3 3 1 3 3 3 3 4 3 3 4 2 4 5 3 2 4 3 4 5 4 3 3 3 4 3 4 3
[38] 4 3 3 4 5 4 3 3 4 3 3 4 2 4 2 2 4 4 2 3 3 3 3 4 3 4 3 2 1 2 1 3 4 3 4 2 4
[75] 2 3 5 3 4 4 4 3 4 3 2 4 3 2 3 3 3 3 4 2 3 3 3 3 4 4 3 3 3 4 3 3 3 4 4 3 1 3
[112] 3 3 3 4 4 3 4 5 4 4 5 3 3 4 3 4 4 4 3 3 3 4 1 2 4 3 2 3 1 4 3 2 4 3 3 4 4
[149] 3 2 5 2 4 2 3 3 3 4 3 3 4 3 4 4 3 4 4 3 3 4 4 3 2 4 5 3 2 4 3 4 3 3 3 3 3 3
[186] 4 3 3 3 3 3 2 4 3 3 2 4 4 4 4 3 2 3 3 3 4 4 1 3 3 2 4 3 5 3 3 3 4 4 5 3 2 1 4
[223] 5 3 5 3 4 4 5 3 4 5 3 4 3 3 4 4 5 3 3 3 5 4 3 4 2 3 2 4 3 4 3 3 4 5 4 2 3
[260] 3 3 3 5 2 5 4 3 2 3 5 1 4 2 3 4 3 4 3 4 3 2 1 3 3 3 2 3 4 4 2 3 4 3 4 4 3
[297] 3 3 2 4 3 5 4 2 2 4 4 4 4 5 3 1 3 4 4 4 3 3 3 5 4 5 4 4 3 2 2 4 4 5 4 3 4 5
[334] 3 3 4 4 3 3 3 2 1 4 3 4 3 4 3 5 5 2 3 1 2 1 3 3 3 4 2 3 4 4 2 3 3 2 2 3 3
[371] 4 3 3 3 3 3 3 5 3 3 4 4 3 4 3 2 4 3 4 5 3 2 4 2 3 3 3 4 3 3 3 3 4 4 4 4 1 4 3
[408] 4 3 2 3 3 3 3 3 4 3 1 2 4 2 5 2 3 2 3 2 4 2 3 2 3 4 3 3 3 3 3 2 3 4 3 3 3
[445] 3 3 3 5 3 3 3 1 3 3 4 4 3 2 3 5 3 4 1 5 4 4 3 2 3 3 3 4 3 5 4 3 4 4 3 3 4 5
[482] 4 3 4 2 3 5 4 4 4 3 4 3 4 3 3 4 5 5 3 3 3 5 3 3 1 5 3 4 3 4 5 3 2 2 5 5 3
[519] 2 3 3 4 2 4 3 3 3 2 5 2 4 5 5 3 3 5 3 4 2 3 3 3 3 3 4 4 4 1 4 3 3 4 2 5 4
[556] 3 4 3 3 2 5 4 5 3 3 4 5 4 3 2 2 4 4 3 2 4 2 3 2 3 3 2 3 3 3 4 5 3 4 3 3 4
[593] 2 4 3 3 4 3 4 3 4 3 3 4 3 2 2 3 3 3 2 4 3 4 2 5 5 3 5 3 3 5 3 4 3 1 3 2 3
[630] 3 5 1 4 3 5 3 2 3 2 4 5 2 3 1 4 4 3 2 4 3 4 3 4 3 2 4 3 4 4 3 4 3 5 4 3 3
[667] 3 3 3 5 2 3 2 3 4 4 3 5 3 3 4 1 3 4 1 3 5 3 5 4 5 3 3 4 2 3 3 5 2 3 3 3 4
[704] 3 3 4 3 3 3 3 3 5 4 1 2 3 2 4 2 2 3 5 3 3 3 5 3 4 3 5 3 2 3 4 4 5 4 3 1 3
[741] 4 3 5 4 3 1 3 3 4 4 3 5 4 3 4 4 4 2 3 4 3 5 3 3 3 4 4 3 1 3 5 2 4 1 2 3 2
```

```
[778] 3 2 3 4 3 5 5 4 3 4 4 3 2 3 3 3 1 3 3 3 3 2 4 4 3 3 2 3 4 4 3 3 4 3 5 4 3
[815] 4 3 4 1 4 1 4 3 4 5 2 4 2 3 4 3 2 5 4 3 4 4 3 4 2 5 3 2 2 4 3 4 4 4 4 3 5
[852] 3 2 4 5 4 4 5 2 2 3 1 3 4 5 5 3 2 3 3 5 2 4 3 3 2 4 2 3 1 3 2 2 2 3 2 5 1
[889] 4 4 5 5 5 4 2 5 2 3 4 1 4 3 5 5 3 2 4 4 4 3 2 2 4 3 3 4 3 3 3 3 2 3 2 3
[926] 5 5 4 3 4 3 4 4 3 1 2 4 5 4 3 5 1 2 4 5 4 4 5 3 3 4 3 4 4 3 4 2 4 2 4 5 4
[963] 3 2 4 5 4 2 4 2 3 4 3 4 3 2 4 2 3 2 3 4 2 4 2 3 3 3 2 2 4 1 3 4 1 4 3 4 4
[1000] 3 5 4 2 5 4 5 2 3 3 3 4 3 4 3 3 4 3 3 4 4 2 3 3 5 3 2 5 3 3 3 3 4 3 4 4 5
[1037] 2 4 3 4 2 3 2 2 4 3 3 3 4 4 2 5 3 3 3 4 3 3 5 4 4 4 2 3 4 5 1 4 3 1 2 5 4
[1074] 4 3 4 5 4 4 3 4 3 3 4 4 4 3 3 3 4 2 4 2 4 3 2 4 4 3 3 2 3 5 5 4 3 3 5 3 4
[1111] 2 2 3 4 5 3 4 5 4 4 3 3 3 3 3 3 4 4 3 3 4 4 3 3 4 3 2 4 5 5 5 5 2 4 3 4 3
[1148] 4 4 2 5 4 3 2 2 3 2 4 3 3 3 4 4 5 3 2 2 3 4 4 2 4 5 3 5 1 4 3 2 5 3 4 4 3 3
[1185] 4 1 5 2 4 5 3 3 4 4 3 4 3 5 5 2 3 2 3 4 4 3 2 4 4 3 2 4 3 3 3 2 5 4 1 3 5
[1222] 4 4 3 3 3 3 4 4 2 3 4 2 5 5 4 5 4 5 2 5 2 5 4 3 3 3 4 3 5 3 4 4 3 4 4 4 3 3
[1259] 2 4 2 3 4 4 4 3 4 2 4 2 4 3 4 3 2 2 4 5 5 4 3 3 3 4 4 2 3 3 3 4 4 3 3 5 1 4
[1296] 3 4 3 2 3 4 3 3 4 5 3 3 4 3 4 3 2 4 4 3 3 3 5 3 4 3 5 4 4 3 4 3 5 1 4 3 1
[1333] 2 4 4 5 3 4 4 3 3 3 4 3 3 5 4 3 1 3 3 5 3 3 3 4 2 3 5 3 2 4 3 4 1 3 4 1 5
[1370] 3 4 3 3 3 4 3 3 5 4 5 4 3 4 2 4 5 2 4 3 3 5 5 3 2 4 5 4 4 3 3 2 3 2 2 3 3
[1407] 4 4 5 3 4 2 3 2 3 1 2 1 2 3 2 3 3 3 4 4 1 4 2 5 3 5 2 4 4 3 4 4 4 5 3 2 3
[1444] 1 5 3 4 3 3 3 2 4 3 4 4 3 4 3 2 4 3 4 2 4 3 3 5 4 3 5 4 2 5 4 4 2 3 2 3 3
[1481] 3 2 5 5 5 4 4 1 3 4 3 4 3 2 5 3 4 3 3 5 1 4 4 4 4 3 3 3 3 4 3 4 3 4 2 3 3 3
[1518] 3 5 4 5 5 3 2 4 3 4 4 3 3 4 3 4 3 3 2 4 4 4 5 2 4 4 1 3 3 3 5 3 3 3 5 3 3 3
[1555] 3 5 4 3 2 2 4 3 3 2 3 3 3 3 3 4 4 5 5 4 2 4 3 2 3 4 4 3 1 4 2 1 5 4 2 4 3
[1592] 3 2 3 3 4 5 3 2 2 4 1 3 2 5 3 3 3 3 2 4 5 5 5 4 3 5 5 4 2 4 3 5 3 1 4 5 3 2
[1629] 4 5 5 3 2 3 3 4 1 3 5 2 3 3 2 4 3 2 3 2 3 5 3 2 2 5 3 2 4 4 4 3 4 2 4 2 3
[1666] 2 4 2 5 5 1 3 4 2 3 5 3 3 5 5 3 4 4 2 2 4 2 4 3 4 4 4 3 3 2 2 2 4 5 2 3 3
[1703] 5 1 3 4 5 2 3 5 5 3 2 2 4 3 3 5 3 4 4 3 3 5 3 4 4 4 4 3 3 4 4 5 4 4 3 3 3 3
[1740] 4 3 3 4 2 2 5 3 4 4 2 3 4 4 2 4 3 3 2 3 2 4 2 4 4 4 4 5 2 2 3 4 3 2 4 2 4 2 4
[1777] 4 4 4 4 3 2 4 4 3 4 4 4 5 4 5 2 2 2 2 3 5 4 5 2 2 1 4 4 2 4 1 3 5 2 4 5 3 1
[1814] 3 5 4 2 3 3 3 3 2 4 3 5 3 5 3 4 1 5 5 2 3 4 2 5 4 3 5 4 5 3 4 3 4 5 3 4 4
[1851] 4 3 3 5 1 2 5 3 3 1 2 4 3 4 3 3 4 4 1 5 3 3 3 4 1 2 3 5 5 2 4 3 2 4 4 2 3
[1888] 2 4 5 4 3 2 3 5 3 1 3 2 3 1 2 3 2 4 3 3 3 3 4 4 3 4 4 3 4 2 4 2 3 3 5 3 4
[1925] 5 3 4 3 4 4 5 4 1 4 3 3 3 2 2 5 1 4 4 3 3 3 4 4 4 4 4 2 4 3 4 1 4 5 2 4 3 5
[1962] 1 3 3 3 4 5 2 3 3 4 3 3
```

Within cluster sum of squares by cluster:


```
[1] 54.2000 108.4060 401.9303 622.3750 127.0700
(between_SS / total_SS = 66.7 %)
```

Available components:

```
[1] "cluster"      "centers"       "totss"        "withinss"      "tot.withinss"
[6] "betweenss"    "size"          "iter"         "ifault"
```

# コード 10-8

```
fviz_cluster(
  K_shopping, # k-means 法の結果
  data = clus_cons, # クラスター分析対象データ
  geom = "point" # プロットの形状
) +
  labs( # タイトルと軸ラベル
    title = "k = 5",
    x = "Brand switching(Std. score)",
    y = "Price orientation(Std. score)"
)
```



```
# コード 10-9
df_cons$cluster_id <- factor(K_shopping$cluster)

knitr::kable(head(df_cons), caption = "結合データ")
```

Table7.1: 結合データ

| 県<br>番号 | 性<br>別 | 年<br>齢 | 結婚<br>有無 | q12_4 | q13_3 | Pref  | Gen-<br>der | Mari-<br>talSt. | clus-<br>ter_id |
|---------|--------|--------|----------|-------|-------|-------|-------------|-----------------|-----------------|
| 13      | 2      | 38     | 2        | 4     | 4     | Tokyo | Fe-<br>male | Not<br>Married  | 5               |
| 13      | 1      | 42     | 2        | 4     | 5     | Tokyo | Male        | Not<br>Married  | 5               |
| 13      | 1      | 30     | 1        | 5     | 4     | Tokyo | Male        | Married         | 5               |
| 13      | 1      | 33     | 1        | 2     | 1     | Tokyo | Male        | Married         | 4               |
| 28      | 1      | 25     | 1        | 3     | 3     | Hyogo | Male        | Married         | 3               |
| 28      | 1      | 32     | 1        | 3     | 3     | Hyogo | Male        | Married         | 3               |

```
# コード 10-10

clus_summary <- df_cons |>
  group_by(cluster_id) |>
  summarize(
    N = n(),
    Loyalty_m = mean(q12_4),
    Price_m = mean(q13_3),
    Age_m = mean(年齢),
    Male_r = sum(Gender == "Male") / n(),
    Tokyo_r = (sum(Pref == "Tokyo") / n()) / (1465 / 1973),
    Married_r = sum(MaritalSt. == "Married") / n()
  )
# 表示
knitr::kable(clus_summary, caption = "クラスターサマリー")
```

Table7.2: クラスターサマリー

| clus-<br>ter_id | N   | Loy-<br>alty_m | Price_m  | Age_m    | Male_r    | Tokyo_r   | Mar-<br>ried_r |
|-----------------|-----|----------------|----------|----------|-----------|-----------|----------------|
| 1               | 80  | 1.000000       | 3.850000 | 42.61250 | 0.5125000 | 0.8753925 | 0.5250000      |
| 2               | 298 | 2.738255       | 4.218121 | 38.56040 | 0.5134228 | 0.9400188 | 0.6107383      |
| 3               | 760 | 3.417105       | 2.792105 | 41.88816 | 0.5065789 | 1.0100683 | 0.5618421      |
| 4               | 592 | 2.552365       | 1.876689 | 43.79730 | 0.4645270 | 1.0191680 | 0.4712838      |
| 5               | 243 | 4.300412       | 4.222222 | 34.91770 | 0.5102881 | 1.0363938 | 0.6213992      |

## 第 8 章

## 第 11 章

```

pacman::p_load(psych, GPArotation, tidyverse, readxl, gt, gtExtras,
  ↵  dendextend, cluster, factoextra, useful, ggrepel)

# コード 11-1
# install.packages("psych")
# install.packages("GPArotation")

# コード 11-2
factor_exdata <- readxl::read_excel("data/factor_ex.xlsx", na = ".")  

factor_exdata$V5 <- 8 - factor_exdata$V5
rownames(factor_exdata) <- factor_exdata$ID  

factor_exdata2 <- factor_exdata %>%
  select(-ID)
knitr::kable(summary(factor_exdata2))

```

| V1          | V2        | V3        | V4        | V5        | V6          |
|-------------|-----------|-----------|-----------|-----------|-------------|
| Min. :1.000 | Min. :2.0 | Min. :1.0 | Min. :2.0 | Min. :1.0 | Min. :2.000 |
| 1st         | 1st       | 1st       | 1st       | 1st       | 1st         |
| Qu.:2.000   | Qu.:3.0   | Qu.:2.0   | Qu.:3.0   | Qu.:3.0   | Qu.:3.000   |
| Median      | Median    | Median    | Median    | Median    | Median      |
| :4.000      | :4.0      | :4.0      | :4.0      | :4.5      | :4.000      |
| Mean :3.933 | Mean :3.9 | Mean :4.1 | Mean :4.1 | Mean :4.5 | Mean :4.167 |
| 3rd         | 3rd       | 3rd       | 3rd       | 3rd       | 3rd         |
| Qu.:6.000   | Qu.:5.0   | Qu.:6.0   | Qu.:5.0   | Qu.:6.0   | Qu.:4.750   |
| Max. :7.000 | Max. :7.0 | Max. :7.0 | Max. :7.0 | Max. :7.0 | Max. :7.000 |


```
# コード 11-3
knitr::kable(cor(factor_exdata2), caption = "相関行列")
```

Table8.2: 相関行列

|    | V1         | V2         | V3         | V4         | V5         | V6         |
|----|------------|------------|------------|------------|------------|------------|
| V1 | 1.0000000  | -0.0532178 | 0.8730902  | -0.0861622 | 0.8576366  | 0.0041681  |
| V2 | -0.0532178 | 1.0000000  | -0.1550200 | 0.5722121  | -0.0197456 | 0.6404649  |
| V3 | 0.8730902  | -0.1550200 | 1.0000000  | -0.2477879 | 0.7778480  | -0.0180688 |
| V4 | -0.0861622 | 0.5722121  | -0.2477879 | 1.0000000  | 0.0065819  | 0.6404649  |
| V5 | 0.8576366  | -0.0197456 | 0.7778480  | 0.0065819  | 1.0000000  | 0.1364029  |
| V6 | 0.0041681  | 0.6404649  | -0.0180688 | 0.6404649  | 0.1364029  | 1.0000000  |

```
# コード 11-4
cor.exdata <- cor(factor_exdata2)

VSS.scree(cor.exdata)
```



```
# コード 11-5
fa <- fa(r = factor_exdata2, nfactors = 2,
          rotate = "promax", fm = "ml")
fa
```

```
Factor Analysis using method = ml
Call: fa(r = factor_exdata2, nfactors = 2, rotate = "promax", fm = "ml")
```

Standardized loadings (pattern matrix) based upon correlation matrix

|    | ML1   | ML2   | h2   | u2    | com |
|----|-------|-------|------|-------|-----|
| V1 | 0.97  | 0.00  | 0.94 | 0.063 | 1   |
| V2 | -0.02 | 0.75  | 0.56 | 0.437 | 1   |
| V3 | 0.89  | -0.12 | 0.83 | 0.174 | 1   |
| V4 | -0.06 | 0.78  | 0.62 | 0.378 | 1   |
| V5 | 0.89  | 0.11  | 0.79 | 0.205 | 1   |
| V6 | 0.08  | 0.83  | 0.69 | 0.309 | 1   |

ML1 ML2

|                       | SS loadings | ML1  | ML2 |
|-----------------------|-------------|------|-----|
| Proportion Var        | 0.42        | 0.32 |     |
| Cumulative Var        | 0.42        | 0.74 |     |
| Proportion Explained  | 0.57        | 0.43 |     |
| Cumulative Proportion | 0.57        | 1.00 |     |

With factor correlations of

|     | ML1   | ML2   |
|-----|-------|-------|
| ML1 | 1.00  | -0.06 |
| ML2 | -0.06 | 1.00  |

Mean item complexity = 1

Test of the hypothesis that 2 factors are sufficient.

df null model = 15 with the objective function = 4.25 with Chi Square = 111.31  
 df of the model are 4 and the objective function was 0.21

The root mean square of the residuals (RMSR) is 0.03

The df corrected root mean square of the residuals is 0.05

The harmonic n.obs is 30 with the empirical chi square 0.65 with prob < 0.96  
 The total n.obs was 30 with Likelihood Chi Square = 5.21 with prob < 0.27

Tucker Lewis Index of factoring reliability = 0.95

RMSEA index = 0.095 and the 90 % confidence intervals are 0 0.314

BIC = -8.39

Fit based upon off diagonal values = 1


Measures of factor score adequacy

ML1 ML2

```
Correlation of (regression) scores with factors      0.98 0.92
Multiple R square of scores with factors           0.96 0.84
Minimum correlation of possible factor scores    0.92 0.68
```

```
# コード 11-6
fa.diagram(fa)
```

## Factor Analysis



```
# コード 11-7
fs <- data.frame(fa$scores)
factor_exdata2$rowname <- rownames(factor_exdata2)
fs$rowname <- rownames(fs)
factor_exdata2 <- left_join(factor_exdata2, fs, by = "rowname")
knitr::kable(head(factor_exdata2), caption = "結合後データ")
```

Table8.3: 結合後データ

| V1 | V2 | V3 | V4 | V5 | V6 | rowname | ML1        | ML2        |
|----|----|----|----|----|----|---------|------------|------------|
| 7  | 3  | 6  | 4  | 6  | 4  | 1       | 1.3106155  | -0.2896470 |
| 1  | 3  | 2  | 4  | 3  | 4  | 2       | -1.2878038 | -0.2073067 |
| 6  | 2  | 7  | 4  | 7  | 3  | 3       | 1.1828544  | -0.7996332 |
| 4  | 5  | 4  | 6  | 6  | 5  | 4       | 0.1474225  | 1.0035837  |
| 1  | 2  | 2  | 3  | 2  | 2  | 5       | -1.3907544 | -1.3067260 |
| 6  | 3  | 6  | 4  | 6  | 4  | 6       | 0.9928111  | -0.2875982 |

```
# コード 11-8

ex_cluster <- factor_exdata2 %>%
  select(ML1, ML2)
Hier1 <- agnes(ex_cluster, metric = "euclidian", stand = TRUE)
pltree(Hier1)
```

Program of `agnes(x = ex_cluster, metric = "euclidian", stand = TRUE)`




```
ex_cluster
agnes (*, "average")
```

```
# コード 11-9

cl_1 <- kmeans(ex_cluster, 3)
clus_fa <- data.frame(cl_1$cluster)
clus_fa$rownames <- rownames(clus_fa)
factor_exdata2 <- left_join(factor_exdata2, clus_fa, by = "rownames")
factor_exdata2$cl_1.cluster <- factor(factor_exdata2$cl_1.cluster)

# Visualizing the clusters with 2 factors
p1 <- ggplot(data = factor_exdata2,
               mapping = aes(x = ML1, y = ML2, color = cl_1.cluster))
p1 + geom_point() +
  geom_text_repel(mapping = aes(label = rownames(factor_exdata2))) +
  labs(x = "Ease of use", y = "Design")
```



```
# コード 11-10
factor_exdata3 <- factor_exdata %>%
  select(-ID)
pca_res <- pca(factor_exdata3, nfactors = 2, rotate = "none")
pca_res
```

Principal Components Analysis  
Call: principal(r = r, nfactors = nfactors, residuals = residuals,  
rotate = rotate, n.obs = n.obs, covar = covar, scores = scores,  
missing = missing, impute = impute, oblique.scores = oblique.scores,  
method = method, use = use, cor = cor, correct = 0.5, weight = NULL)  
Standardized loadings (pattern matrix) based upon correlation matrix

|    | PC1   | PC2  | h2   | u2    | com |
|----|-------|------|------|-------|-----|
| V1 | 0.93  | 0.25 | 0.93 | 0.074 | 1.1 |
| V2 | -0.30 | 0.80 | 0.72 | 0.277 | 1.3 |
| V3 | 0.94  | 0.13 | 0.89 | 0.106 | 1.0 |
| V4 | -0.34 | 0.79 | 0.74 | 0.261 | 1.4 |
| V5 | 0.87  | 0.35 | 0.88 | 0.122 | 1.3 |
| V6 | -0.18 | 0.87 | 0.79 | 0.210 | 1.1 |

|                | PC1  | PC2  |
|----------------|------|------|
| SS loadings    | 2.73 | 2.22 |
| Proportion Var | 0.46 | 0.37 |
| Cumulative Var | 0.46 | 0.82 |

```

Proportion Explained 0.55 0.45
Cumulative Proportion 0.55 1.00

Mean item complexity = 1.2
Test of the hypothesis that 2 components are sufficient.

```

```

The root mean square of the residuals (RMSR) is 0.07
with the empirical chi square 3.94 with prob < 0.41

```

Fit based upon off diagonal values = 0.98

```

# コード 11-11
# データの相関行列から固有値と固有ベクトルを抽出
cor_ex <- cor(factor_exdata3)
eigen_list <- eigen(cor_ex)

# 固有ベクトルについての情報をオブジェクトとして定義
pc1_eig <- eigen_list$vectors[, 1]
pc2_eig <- eigen_list$vectors[, 2]

# 固有ベクトルに、固有値の平方根を乗じる
PC1 <- pc1_eig * sqrt(eigen_list$values[1])
PC2 <- pc2_eig * sqrt(eigen_list$values[2])
knitr::kable(data.frame(cbind(PC1, PC2)), caption = "計算結果")

```

Table8.4: 計算結果

|  | PC1        | PC2        |
|--|------------|------------|
|  | 0.9283425  | -0.2532285 |
|  | -0.3005297 | -0.7952496 |
|  | 0.9361812  | -0.1308894 |
|  | -0.3415817 | -0.7889663 |
|  | 0.8687553  | -0.3507939 |
|  | -0.1766389 | -0.8711581 |



## 第9章

## 第12章

```
pacman::p_load(pricesensitivitymeter, tidyverse)
#コード 12-1
# install.packages("pricesensitivitymeter")
# library(pricesensitivitymeter)
# library(tidyverse)

#コード 12-2
psm_ex <- read.csv("data/psm_ex.csv", na = ".")
head(psm_ex)
```

|   | tch  | ch   | ex   | tex  |
|---|------|------|------|------|
| 1 | 963  | 1016 | 1242 | 1318 |
| 2 | 866  | 1082 | 1272 | 1303 |
| 3 | 795  | 824  | 1290 | 1297 |
| 4 | 812  | 933  | 1211 | 1335 |
| 5 | 1026 | 818  | 1228 | 1289 |
| 6 | 912  | 987  | 1195 | 1395 |

```
#コード 12-3
output_psm <- psm_analysis(
  toocheap = "tch",
  cheap = "ch",
  expensive = "ex",
  tooexpensive = "tex",
  data = psm_ex
)

summary(output_psm)
```

### Van Westendorp Price Sensitivity Meter Analysis

Accepted Price Range: 922.5 - 1253

Indifference Price Point: 1101

Optimal Price Point: 1058

---

157 cases with individual price preferences were analyzed (unweighted data).

Total data set consists of 250 cases. Analysis was limited to cases with transitions  
(Removed: n = 93 / 37% of data)

```
#コード 12-4
psm_plot(output_psm) +
  labs(
    x = "Price",
    y = "Share of Respondents (0-1)",
    title = "Price Sensitivity Meter Plot",
    caption = "Shaded area: range of acceptable prices\nData: Randomly
      generated") +
  theme_minimal()
```

